

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 00

Distribuciones de datos y modelado generativo

Curso abierto OpenCourses.AI | 2026

El objetivo de un modelo generativo no es almacenar ejemplos, sino construir un procedimiento que produzca nuevas muestras plausibles de una distribución de datos.

1 Motivación

El punto de partida del modelado generativo es una reformulación probabilística de la generación. En lugar de preguntar cómo construir una imagen particular, preguntamos cómo muestrear de una distribución de datos. Esta diferencia es fundamental: no buscamos una única imagen correcta, sino una familia de objetos plausibles.

En el Notebook 00 trabajamos con dibujos de casas de QuickDraw. Esta elección permite estudiar el problema en un espacio pequeño, pero no trivial. Cada dibujo es una imagen de tamaño 28×28 , suficientemente simple para visualizar y suficientemente variable para exigir una formulación estadística.

Idea clave 1 (Generación como muestreo). Generar una muestra significa producir un objeto x distribuido aproximadamente como una distribución de datos p_{data} . En notación idealizada:

$$x \sim p_{\text{data}}(x).$$

Esta nota desarrolla la formulación detrás del notebook: objetos como vectores, datasets como muestras empíricas, distribución empírica, objetivo general del modelado generativo, y el mapa inicial entre la lectura discreta y la lectura continua de los modelos de difusión.

2 Objetos como vectores

Aunque visualmente observamos dibujos, computacionalmente cada muestra es un arreglo numérico. Una imagen de QuickDraw de tamaño 28×28 puede representarse como una matriz de intensidades:

$$x \in [0, 1]^{28 \times 28}.$$

También puede aplanarse como un vector:

$$x \in \mathbb{R}^{784}.$$

Esta representación no implica que la estructura espacial de la imagen sea irrelevante. Las arquitecturas que usaremos más adelante, como redes convolucionales o U-Net, aprovecharán precisamente esa estructura. Sin embargo, para formular el problema generativo es útil reconocer que cada imagen corresponde a un punto en un espacio de alta dimensión.

Idea clave 2 (Objetos como vectores). En este curso, los objetos generados se representarán como vectores $x \in \mathbb{R}^d$. Para QuickDraw con imágenes de 28×28 , se tiene $d = 784$.

3 Dataset y distribución de datos

Sea $\mathcal{D}$ un conjunto de entrenamiento formado por N observaciones:

$$\mathcal{D} = \{x_i\}_{i=1}^N.$$

La hipótesis estadística central es que las observaciones del dataset son muestras de una distribución desconocida:

$$x_i \sim p_{\text{data}}(x), \quad i = 1, \dots, N.$$

En el caso de QuickDraw, p_{data} representa la distribución de dibujos de casas producidos por personas bajo las condiciones del experimento. No conocemos una fórmula cerrada para esta distribución. Solo observamos muestras finitas.

Idea clave 3 (Dataset). Un dataset no es la distribución completa. Es una colección finita de muestras que usamos como evidencia empírica de una distribución desconocida p_{data} .

Comenzar con una sola categoría, **house**, evita introducir desde el inicio una mezcla semántica de distribuciones. Si mezcláramos casas, gatos y árboles, el objeto estadístico sería más cercano a una mezcla:

$$p_{\text{data}}(x) = \sum_y p_{\text{data}}(x | y)p(y).$$

Esta formulación será útil cuando estudiemos modelos condicionales. Por ahora nos interesa aislar una única familia visual.

4 Distribución empírica y memorización

Antes de entrenar un modelo, existe un procedimiento trivial para producir una imagen válida: escoger una muestra aleatoria del dataset. Este procedimiento corresponde a muestrear de la distribución empírica:

$$\hat{p}_{\text{data}}(x) = \frac{1}{N} \sum_{i=1}^N \delta(x - x_i),$$

donde $\delta(x - x_i)$ representa una masa puntual en la observación x_i .

La distribución empírica es útil para describir el conjunto observado, pero no resuelve el problema generativo. Muestrear de $\hat{p}_{\text{data}}$ equivale a devolver elementos almacenados.

Observación 1 (Muestreo empírico no es modelado generativo). Elegir una imagen aleatoria del dataset produce una muestra válida, pero no aprende una regla generativa. El modelo generativo debe inducir una distribución capaz de producir muestras plausibles más allá de la recuperación directa de ejemplos.

5 Modelo generativo

La formulación ideal del objetivo es construir una distribución parametrizada p_θ que aproxime la distribución de datos:

$$p_\theta(x) \approx p_{\text{data}}(x).$$

Aquí θ representa los parámetros del modelo. En algunos modelos, $p_\theta(x)$ puede evaluarse o aproximarse como una densidad explícita. En muchos modelos generativos modernos, incluidos los modelos de difusión, p_θ queda definida de manera implícita por un procedimiento de muestreo.

Por tanto, la expresión $p_\theta(x) \approx p_{\text{data}}(x)$ debe leerse como una formulación del objetivo, no como la promesa de obtener una fórmula cerrada para la distribución de datos.

Idea clave 4 (Modelo generativo). Un modelo generativo es un procedimiento, parametrizado por θ , que induce una distribución p_θ desde la cual podemos obtener muestras plausibles.

6 Dos lecturas de la difusión generativa

La expresión $p_\theta(x) \approx p_{\text{data}}(x)$ define el objetivo estadístico, pero no especifica todavía cómo construir el procedimiento de muestreo. En modelos basados en ruido, la pregunta operativa es cómo transformar una distribución simple en una distribución estructurada:

$$\text{ruido simple} \longrightarrow \text{datos plausibles}.$$

Esta transformación puede describirse con dos niveles de formalización. La primera lectura es discreta: se define una cadena finita de variables aleatorias

$$x_0 \rightarrow x_1 \rightarrow \cdots \rightarrow x_T,$$

donde x_0 es una muestra de datos y x_T se aproxima a ruido gaussiano. Esta lectura conduce a modelos tipo DDPM y será la ruta principal de la primera parte del curso, porque permite implementar y visualizar cada paso de corrupción y denoising.

La segunda lectura es continua. En lugar de una cadena finita, se considera una trayectoria estocástica $(X_t)_{0 \leq t \leq 1}$. Una formulación típica se escribe mediante una ecuación diferencial estocástica:

$$dX_t = f(t, X_t) dt + g(t) dW_t,$$

donde $f(t, X_t)$ describe una deriva o campo vectorial, $g(t)$ controla la intensidad de la fluctuación y W_t denota movimiento browniano. Su conexión mínima con el ruido gaussiano está dada por

$$W_{t+h} - W_t \sim \mathcal{N}(0, hI).$$

Dos lecturas matemáticas de la difusión generativa

La primera se implementa como pasos discretos; la segunda idealiza esos pasos como una trayectoria estocástica.

Lectura discreta

Cadena finita de ruido

$X_0 \rightarrow X_1 \rightarrow \dots \rightarrow X_T$




cada paso usa una varianza controlada β_t

Lectura continua

Trayectoria estocástica


$dX_t = f(t, X_t)dt + g(t)dW_t$



Campo vectorial

Parte determinista local

$f(t, X_t)dt$ orienta el movimiento medio



Observación 2 (Discreto y continuo). La lectura continua no reemplaza a la discreta. La lectura discreta puede entenderse como una forma computacional de trabajar con pasos finitos; la lectura continua idealiza esos pasos como una trayectoria estocástica. En este curso empezaremos por la formulación discreta por razones conceptuales y computacionales, sin ocultar que existe una formulación más general basada en SDEs.

Una forma elemental de conectar ambas miradas es discretizar la dinámica continua. Si aproximamos la SDE por pasos pequeños, obtenemos una actualización del tipo

$$X_{k+1} = X_k + f(t_k, X_k)\Delta t + \sigma(t_k)\sqrt{\Delta t}\xi_k, \quad \xi_k \sim \mathcal{N}(0, I).$$

El término $f(t_k, X_k)\Delta t$ representa la contribución determinista de la deriva. El término $\sigma(t_k)\sqrt{\Delta t}\xi_k$ representa la fluctuación browniana discretizada. Es importante leer esta suma con cuidado: el ruido no modifica el campo vectorial; modifica la trayectoria realizada, porque en cada paso se añade una perturbación aleatoria a la dirección media.

Deriva y fluctuación browniana en una discretización estocástica

$$X_{k+1} = X_k + f(t_k, X_k)\Delta t + \sigma(t_k)\sqrt{\Delta t}\xi_k, \quad \xi_k \sim \mathcal{N}(0, I)$$

La deriva fija la tendencia local; la componente browniana introduce fluctuaciones en la trayectoria realizada.




Figura complementaria. Separación entre deriva determinista, fluctuación browniana y trayectorias resultantes bajo distintos niveles de intensidad estocástica.

Idea clave 5 (Ruta del curso). El mapa conceptual del curso parte de datos, introduce ruido por pasos discretos, formula un problema de denoising aprendido y finalmente usa ese denoising para muestreo generativo. La lectura continua se conserva como horizonte formal, pero la implementación inicial se hará con cadenas discretas.

7 Ruido gaussiano como distribución de referencia

Una variable aleatoria gaussiana estándar se escribe como:

$$z \sim \mathcal{N}(0, I).$$

A diferencia de p_{data} , esta distribución es conocida y fácil de muestrear. Si reorganizamos muestras gaussianas como imágenes de 28×28 , obtenemos patrones sin estructura semántica. Esta falta de estructura no es un defecto; es precisamente lo que hace útil al ruido como punto de partida.

La pregunta que prepara los modelos de difusión es:

¿cómo transformar ruido simple en datos estructurados?


La dificultad no está en producir números aleatorios. La dificultad está en aprender una transformación que lleve muestras de una distribución simple hacia regiones del espacio donde se concentran los datos plausibles.

8 Interpretación de las visualizaciones empíricas

8.1 Muestras del dataset

La grilla de casas evidencia variabilidad real: techos diferentes, proporciones distintas, presencia o ausencia de puertas, ventanas y estilos de trazo. Esta variabilidad justifica el lenguaje probabilístico. No hay una única casa correcta; hay una familia de muestras plausibles.


Muestras empíricas de QuickDraw: house



Esta figura conecta la noción abstracta de muestra con objetos concretos del dataset. Las diferencias entre dibujos no son ruido accidental: son parte de la variabilidad que una distribución de datos debe representar.

8.2 Imagen como vector

La visualización de una imagen como vector muestra que el objeto visual puede interpretarse como un punto en $\mathbb{R}^{784}$. La representación mediante barras es preferible a una curva continua, porque las coordenadas del vector son discretas y no forman una señal temporal.



La figura muestra la misma observación en dos formas: como arreglo espacial 28×28 y como

vector de 784 coordenadas. Esta doble lectura será usada constantemente: las ecuaciones suelen escribirse para vectores, mientras que las visualizaciones recuperan la forma de imagen.

8.3 Promedio y desviación estándar


El promedio empírico se define como:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i.$$

La desviación estándar empírica pixel a pixel se define como:

$$\hat{\sigma} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}.$$

Ambas cantidades pertenecen a $\mathbb{R}^{28 \times 28}$. No son escalares; son imágenes-resumen. El promedio muestra regiones donde los trazos aparecen con frecuencia. La desviación estándar muestra regiones donde las casas varían más entre observaciones.



Estas imágenes-resumen no generan casas nuevas, pero sí revelan regularidades de la muestra. El promedio sugiere una silueta frecuente y la desviación estándar localiza regiones de mayor variabilidad; el histograma de intensidad total resume, de forma escalar, cuánto trazo aparece en cada dibujo.

8.4 PCA de datos y ruido

La proyección PCA reduce temporalmente el espacio de 784 dimensiones a dos dimensiones para visualización. Esta reducción no preserva toda la geometría del problema, pero permite contrastar muestras estructuradas y ruido.

Formalmente, si tomamos una submuestra vectorizada $x_1, \dots, x_m \in \mathbb{R}^{784}$, primero centramos los datos:

$$\tilde{x}_i = x_i - \bar{x}, \quad \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i.$$

En el notebook también se estandariza cada coordenada para evitar que la comparación dependa únicamente de diferencias de escala entre píxeles. Si $\hat{\sigma}_j$ es la desviación estándar empírica de la coordenada j , usamos:


$$x_{ij}^{\text{std}} = \frac{x_{ij} - \bar{x}_j}{\hat{\sigma}_j + \varepsilon},$$

donde $\varepsilon > 0$ evita divisiones por cero.

PCA busca direcciones ortonormales $v_1, v_2 \in \mathbb{R}^{784}$ que capturan la mayor varianza de la nube estandarizada. La proyección bidimensional de una muestra x_i se escribe como:

$$y_i = \begin{pmatrix} v_1^\top x_i^{\text{std}} \\ v_2^\top x_i^{\text{std}} \end{pmatrix} \in \mathbb{R}^2.$$

En el notebook se estiman v_1 y v_2 usando las muestras de QuickDraw y luego se proyectan, sobre esos mismos ejes, muestras de ruido gaussiano estándar. Esta comparación no demuestra que conocemos p_{data} . Solo ilustra que, incluso en una proyección de baja dimensión, las muestras del dataset exhiben estructura distinta a la de ruido arbitrario.



La proyección debe leerse con cautela: PCA solo muestra dos direcciones de un espacio de 784 dimensiones. Aun así, la separación visual ayuda a fijar una idea central del notebook: las muestras de datos no ocupan el espacio como ruido gaussiano sin transformar.

9 Resumen

En esta nota se estableció la formulación básica del modelado generativo que será usada durante el curso:

1. Los objetos que queremos generar pueden representarse como vectores $x \in \mathbb{R}^d$.
2. Un dataset $\mathcal{D} = \{x_i\}_{i=1}^N$ se interpreta como una muestra finita de una distribución desconocida p_{data} .
3. Muestrear del dataset corresponde a muestrear de la distribución empírica $\hat{p}_{\text{data}}$, no a aprender un modelo generativo.

4. El objetivo ideal es construir un procedimiento que induzca una distribución $p_\theta(x) \approx p_{\text{data}}(x)$.
5. Los modelos de difusión pueden leerse discretamente como cadenas $x_0 \rightarrow \dots \rightarrow x_T$, o continuamente como trayectorias estocásticas gobernadas por una SDE.
6. El ruido gaussiano $z \sim \mathcal{N}(0, I)$ será la distribución simple de referencia desde la cual construiremos generación.

Estas ideas separan tres objetos que no deben confundirse: la distribución real de datos p_{data} , la distribución empírica $\hat{p}_{\text{data}}$ inducida por el dataset finito y la distribución generativa p_θ inducida por un modelo entrenado. Además, fijan una decisión metodológica: la primera parte del curso estudiará la ruta discreta, mientras que la formulación continua quedará como referencia formal para conectar más adelante con movimiento browniano, campos vectoriales y SDEs.

10 Preguntas de estudio

1. ¿Por qué un dataset puede interpretarse como una muestra empírica de una distribución desconocida?
2. ¿Qué diferencia hay entre $\hat{p}_{\text{data}}(x)$ y $p_{\text{data}}(x)$?
3. ¿Por qué muestrear del dataset no equivale a entrenar un modelo generativo?
4. ¿Qué significa que $p_\theta(x)$ pueda estar definida de forma implícita?
5. ¿Por qué el promedio empírico no debe interpretarse como una imagen generada?
6. ¿Qué aporta representar una imagen como un vector en $\mathbb{R}^{784}$?
7. ¿Qué papel cumple la distribución $\mathcal{N}(0, I)$ en la formulación general del curso?
8. ¿Qué diferencia conceptual hay entre una cadena discreta $x_0 \rightarrow \dots \rightarrow x_T$ y una trayectoria continua $(X_t)_{0 \leq t \leq 1}$?
9. En una actualización $X_{k+1} = X_k + f(t_k, X_k)\Delta t + \sigma(t_k)\sqrt{\Delta t}\xi_k$, ¿qué parte corresponde a deriva y qué parte corresponde a fluctuación aleatoria?

11 Continuidad

El siguiente notebook estudiará el ruido gaussiano como distribución de referencia en espacios de datos. La pregunta que abre esa discusión es directa: si el ruido gaussiano no tiene estructura visual, ¿por qué es tan útil para construir modelos generativos?

Responder esta pregunta permitirá introducir el puente conceptual que define a los modelos de difusión: transformar una distribución simple y conocida en una distribución estructurada de datos.