

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 01

Ruido gaussiano y espacios de datos

Curso abierto OpenCourses.AI | 2026

El ruido gaussiano no es útil porque parezca un dato, sino porque define una distribución simple, conocida y fácil de muestrear en el mismo espacio donde viven los datos.

1 Motivación

El Notebook 00 formuló el objetivo generativo como la aproximación de una distribución de datos $p_{\text{data}}(x)$. Esa distribución es compleja: sus muestras tienen estructura visual, variabilidad semántica y regularidades espaciales que no conocemos mediante una expresión cerrada. El Notebook 01 estudia el extremo opuesto: una distribución simple y completamente especificada.

La distribución gaussiana estándar aparece en modelos generativos modernos como distribución base. En lugar de comenzar desde una imagen estructurada, se comienza desde una muestra aleatoria z producida por una ley conocida. La dificultad del aprendizaje no está en producir ruido, sino en aprender un procedimiento que transforme ese ruido en datos plausibles.

Idea clave 1 (Distribución base). Una distribución base es una distribución desde la cual podemos muestrear directamente y que sirve como punto de partida para construir muestras de una distribución más compleja.

2 Espacio de datos

En QuickDraw trabajamos con imágenes de tamaño 28×28 . Si aplanamos cada imagen, el espacio de representación tiene dimensión

$$d = 28 \cdot 28 = 784.$$

Una imagen del dataset puede escribirse como $x \in [0, 1]^{784}$ después de normalizar sus intensidades. Una muestra gaussiana estándar en el mismo espacio se escribe como

$$z \in \mathbb{R}^{784}.$$

Ambos objetos tienen la misma dimensión y pueden reorganizarse como matrices de 28×28 . Sin embargo, no provienen de la misma distribución. Esta diferencia separa dos ideas que suelen confundirse: pertenecer al mismo espacio vectorial no implica tener la misma estructura estadística.

Observación 1 (Espacio y distribución). El espacio define el tipo de objeto computacional: vectores de dimensión 784. La distribución define cómo se ocupan las regiones de ese espacio. Datos y ruido viven en el mismo espacio, pero no se concentran en las mismas regiones.

3 La gaussiana estándar

La distribución gaussiana estándar en $\mathbb{R}^d$ se denota

$$z \sim \mathcal{N}(0, I_d),$$

donde 0 es el vector de medias y I_d es la matriz identidad de tamaño $d \times d$. Esto equivale a decir que

$$z = \begin{bmatrix} z_1 & z_2 & \cdots & z_d \end{bmatrix}^\top, \quad z_j \sim \mathcal{N}(0, 1),$$


con componentes independientes.

Su densidad está dada por

$$p(z) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{1}{2}\|z\|^2\right).$$

Esta ecuación muestra dos propiedades importantes. Primero, la densidad solo depende de la norma euclidiana $\|z\|$; por tanto, la distribución es isotrópica. La isotropía significa que la distribución no privilegia ninguna dirección del espacio: si rotamos el sistema de coordenadas, la ley probabilística se mantiene igual. Para el modelado generativo, esto es útil porque el ruido inicial no introduce una orientación visual ni una estructura espacial previa. Segundo, la distribución está completamente definida sin necesidad de datos de entrenamiento.

Lectura geométrica de $z \sim \mathcal{N}(0, I_d)$



La figura anterior resume esta lectura geométrica. La matriz identidad representa varianza unitaria por coordenada y covarianzas nulas; los contornos circulares en dimensión dos muestran que ninguna dirección recibe más variabilidad que otra; y la distribución de la norma en $d = 784$ recuerda que, en alta dimensión, una muestra típica aparece alrededor de un radio cercano a $\sqrt{d}$.

Idea clave 2 (Simplicidad computacional). Muestrear de $\mathcal{N}(0, I_d)$

solo requiere generar d números normales independientes. Para $d = 784$, cada muestra gaussiana tiene la misma forma computacional que una imagen aplanada de QuickDraw.

4 Ruido como imagen

Si reorganizamos $z \in \mathbb{R}^{784}$ como una matriz de 28×28 , obtenemos una imagen de ruido. Esta visualización es útil, pero debe interpretarse con precisión. La imagen de ruido no representa una muestra de p_{data} ; representa una muestra de $\mathcal{N}(0, I_{784})$ dibujada sobre la misma grilla.

Para visualizar z como imagen suele aplicarse una normalización de contraste, por ejemplo llevar sus valores al intervalo $[0, 1]$. Esa operación facilita observar el patrón, pero no cambia el hecho matemático central: la muestra original pertenece a una distribución gaussiana sobre $\mathbb{R}^{784}$.

Observación 2 (Visualización y variable original). Normalizar una muestra gaussiana para visualizarla no significa que el modelo trabaje necesariamente con esa versión normalizada. En el notebook se distingue entre el objeto matemático z y su representación visual.

5 Norma típica en alta dimensión

Una fuente frecuente de confusión aparece al observar la densidad gaussiana. Como

$$p(z) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{1}{2}\|z\|^2\right),$$

la densidad máxima ocurre en $z = 0$. Sin embargo, en alta dimensión una muestra típica no cae cerca del origen.

Si $z \sim \mathcal{N}(0, I_d)$, entonces

$$\|z\|^2 = \sum_{j=1}^d z_j^2 \sim \chi_d^2.$$


Por propiedades de la distribución chi-cuadrado,

$$\mathbb{E}[\|z\|^2] = d, \quad \text{Var}(\|z\|^2) = 2d.$$

Esto implica que la norma de una muestra típica está alrededor de

$$\|z\| \approx \sqrt{d}.$$

Para imágenes de QuickDraw, $d = 784$, por lo que $\sqrt{d} = 28$. La muestra típica se encuentra en una región de radio aproximado 28, no cerca del origen.



La figura muestra que, al normalizar la norma por $\sqrt{d}$, las muestras se concentran progresivamente alrededor de 1 cuando la dimensión aumenta. Esta visualización conecta la expresión $\|z\| \approx \sqrt{d}$ con el comportamiento observado por simulación.

Idea clave 3 (Concentración). En alta dimensión, la masa de probabilidad de una gaussiana estándar se concentra en una región de radio cercano a $\sqrt{d}$. La densidad puede ser máxima en el origen, pero el volumen del espacio hace que las muestras típicas aparezcan lejos de él.


6 Datos y ruido

El contraste entre datos y ruido puede resumirse así:

$$x \sim p_{\text{data}}(x), \quad z \sim \mathcal{N}(0, I_d).$$

Ambas variables pueden codificarse como vectores de dimensión d , pero obedecen leyes distintas. Las muestras de p_{data} contienen regularidades visuales: trazos, contornos, zonas vacías y patrones espaciales asociados a dibujos de casas. Las muestras de $\mathcal{N}(0, I_d)$ no contienen esas regularidades.

Mismo espacio ambiente $\mathbb{R}^{784}$, distintas distribuciones



La comparación visual refuerza una distinción central: el dato y el ruido tienen la misma forma computacional, pero sus coordenadas se distribuyen de manera diferente. El ruido puede visualizarse como imagen solo después de una normalización auxiliar; esa normalización no debe confundirse con la variable gaussiana original.

La tarea generativa no consiste en declarar que el ruido ya es una imagen válida. Consiste en aprender una transformación que conecte la distribución base con la distribución de datos. De forma abstracta, puede escribirse:

$$z \sim \mathcal{N}(0, I_d), \quad x = G_\theta(z), \quad x \sim p_\theta(x).$$

Aquí G_θ representa un procedimiento parametrizado que induce una distribución p_θ . En modelos de difusión, este procedimiento no será una única transformación directa simple; será un proceso iterativo que transforma ruido en datos mediante pasos de denoising.

7 Interpretación de las visualizaciones

Las visualizaciones del Notebook 01 cumplen cuatro funciones. Primero, la figura de formulación conecta matriz de covarianza, isotropía y radio típico. Segundo, el histograma unidimensional conecta simulación y densidad normal: las muestras generadas por código siguen la forma de $p(u)$ para $u \sim \mathcal{N}(0, 1)$. Tercero, las imágenes de ruido muestran que una muestra gaussiana puede representarse sobre una grilla visual sin adquirir estructura semántica. Cuarto, la gráfica de normas evidencia que el comportamiento geométrico cambia con la dimensión.

La visualización más importante no es la más llamativa. La concentración de norma prepara una intuición central para difusión: el ruido en alta dimensión no debe pensarse como un punto cerca del origen, sino como una muestra típica de una distribución extendida y altamente regular.

8 Resumen

El ruido gaussiano estándar es una distribución base adecuada porque es conocida, fácil de muestrear, isotrópica y definida en cualquier dimensión. Para imágenes de 28×28 , una muestra $z \sim \mathcal{N}(0, I_{784})$ tiene la misma dimensión que una imagen aplanada, aunque no comparte su estructura estadística.

El hecho de que el ruido no parezca un dato no es una debilidad del enfoque. Al contrario, establece una separación clara entre el punto de partida y el objetivo: comenzar con una distribución simple y aprender un procedimiento que la transforme en una distribución compleja. Esta idea será formalizada en el siguiente notebook mediante el proceso de difusión directa.

9 Preguntas de estudio

1. ¿Por qué pertenecer al mismo espacio vectorial no implica pertenecer a la misma distribución?
2. ¿Qué significa que la gaussiana estándar sea isotrópica?
3. Si $z \sim \mathcal{N}(0, I_d)$, ¿por qué una muestra típica no está cerca del origen cuando d es grande?
4. ¿Qué diferencia hay entre visualizar ruido como imagen y afirmar que el ruido es una imagen válida de la distribución de datos?
5. ¿Qué debe aprender un modelo para convertir $z \sim \mathcal{N}(0, I_d)$ en muestras plausibles de p_{data} ?

10 Continuidad

El siguiente paso es introducir un camino explícito entre datos y ruido. En el proceso de difusión directa se parte de una muestra $x_0 \sim p_{\text{data}}$ y se le agrega ruido gradualmente hasta obtener una variable cada vez más cercana a una distribución gaussiana. Ese proceso permitirá convertir la comparación conceptual de este notebook en una construcción matemática entrenable.