

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 02

Procesos de difusión directa

Curso abierto OpenCourses.AI | 2026

El proceso directo no genera datos nuevos. Construye, de manera fija y controlada, una familia de variables ruidosas que conecta datos estructurados con ruido gaussiano.

1 Motivación

Las notas anteriores establecieron dos extremos del problema generativo. Por un lado, tenemos muestras de una distribución de datos desconocida $p_{\text{data}}(x)$. Por otro, tenemos una distribución gaussiana estándar $\mathcal{N}(0, I)$, conocida, isotrópica y fácil de muestrear. El proceso de difusión directa introduce un camino probabilístico explícito entre estos dos extremos.

La idea consiste en comenzar con una muestra limpia $x_0 \sim p_{\text{data}}$ y construir una secuencia de variables aleatorias

$$x_0, x_1, x_2, \dots, x_T,$$

donde x_t es una versión cada vez más ruidosa de x_0 . Este camino no se aprende. Se define antes del entrenamiento y cumple una función estructural: convierte el problema de generación en un problema inverso de eliminación gradual de ruido.

Idea clave 1 (Proceso directo). El proceso directo de difusión es una cadena probabilística fija que degrada datos mediante ruido gaussiano. Su objetivo no es producir muestras útiles, sino preparar el problema que luego deberá resolver el modelo inverso.

2 Cadena de Markov gaussiana

Sea $x_0 \in \mathbb{R}^d$ una muestra de datos. En el caso de QuickDraw con imágenes de 28×28 , se tiene $d = 784$. Para trabajar en una escala compatible con el ruido gaussiano, las intensidades se normalizan al intervalo $[-1, 1]$.

El proceso directo se define mediante una secuencia de varianzas

$$0 < \beta_1, \beta_2, \dots, \beta_T < 1.$$

Cada β_t determina cuánta varianza gaussiana se agrega en el paso t . Es conveniente introducir

$$\alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s.$$

La transición local se define como

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, \beta_t I).$$

Esta expresión dice que x_t se obtiene reduciendo la señal previa por un factor $\sqrt{\alpha_t}$ y agregando ruido gaussiano isotrópico con varianza β_t . De forma equivalente,

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, I).$$

La presencia de la matriz identidad I no es decorativa. Indica que el ruido agregado tiene la misma varianza en todas las direcciones y que no introduce correlaciones explícitas entre coordenadas. En esta etapa, el proceso no conoce la geometría visual de las casas: solo aplica una perturbación gaussiana controlada en el espacio de datos.

Observación 1 (Markovianidad). El proceso es markoviano porque la distribución de x_t depende de la historia únicamente a través de x_{t-1} .
Formalmente,

$$q(x_t | x_{t-1}, x_{t-2}, \dots, x_0) = q(x_t | x_{t-1}).$$

3 Forma cerrada

Una propiedad esencial del proceso directo es que no es necesario simular todos los pasos intermedios para muestrear x_t condicionado en x_0 . Existe una forma cerrada:


$$q(x_t | x_0) = \mathcal{N}(\sqrt{\alpha_t} x_0, (1 - \alpha_t)I).$$

Por tanto,

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

Esta ecuación es el núcleo computacional del notebook. Permite construir pares (x_0, x_t) para cualquier tiempo t mediante una sola muestra gaussiana. La cantidad $\sqrt{\alpha_t}$ mide el peso de la señal original; la cantidad $\sqrt{1 - \alpha_t}$ mide el peso del ruido agregado.

Forma cerrada del proceso directo: $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$



La figura descompone la ecuación cerrada en tres tiempos. Cuando t es pequeño, el término de señal domina y la estructura visual de la casa permanece reconocible. Cuando t crece, el término de ruido adquiere mayor peso. Para tiempos grandes, x_t se vuelve visualmente indistinguible de una muestra ruidosa.

Idea clave 2 (Muestreo directo de x_t). La forma cerrada convierte una cadena larga en una operación directa. Esto es crucial para el entrenamiento posterior, porque permite construir ejemplos ruidosos en tiempos arbitrarios sin simular paso por paso desde x_0 hasta x_t .


4 Agenda de ruido y relación señal-ruido

La secuencia $\{\beta_t\}_{t=1}^T$ se denomina agenda de ruido. En el notebook se usa una agenda lineal, donde β_t aumenta gradualmente desde un valor pequeño hasta un valor mayor. Esta elección no es la única posible, pero es suficiente para estudiar la mecánica del proceso directo sin introducir una discusión adicional sobre diseño de agendas.

La evolución acumulada está controlada por

$$\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s).$$


Si los β_s son positivos, entonces $\bar{\alpha}_t$ decrece con t . En consecuencia, el peso de la señal $\sqrt{\bar{\alpha}_t}$ disminuye y el peso del ruido $\sqrt{1 - \bar{\alpha}_t}$ aumenta.



La relación señal-ruido se define como

$$\text{SNR}_t = \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t}.$$

Esta cantidad resume qué tan dominante es la señal original frente al ruido. Para tiempos iniciales, SNR_t es grande; para tiempos finales, se aproxima a cero. Desde la perspectiva del problema inverso, una SNR baja indica que recuperar información de x_0 a partir de x_t será más difícil.




La gráfica de pesos muestra directamente la transición entre dos regímenes. Al inicio, el dato limpio domina la construcción de x_t . Al final, la muestra está dominada por ruido. La curva de SNR expresa la misma transición en términos relativos.

5 Distribuciones coordenada por coordenada

La forma cerrada no solo describe una imagen completa; también describe cada coordenada. Si fijamos una coordenada j y condicionamos en $x_{0,j}$, entonces

$$x_{t,j} \mid x_{0,j} \sim \mathcal{N}(\sqrt{\bar{\alpha}_t} x_{0,j}, 1 - \bar{\alpha}_t).$$


Esta expresión es importante porque conecta el proceso visual con una afirmación probabilística verificable. Para un x_0 fijo y un tiempo t fijo, repetir el muestreo muchas veces produce valores $x_{t,j}$ distribuidos normalmente alrededor de $\sqrt{\bar{\alpha}_t} x_{0,j}$, con varianza $1 - \bar{\alpha}_t$.




El histograma de simulación y la densidad teórica coinciden. Esta coincidencia no prueba un modelo aprendido; confirma que la implementación computacional reproduce la distribución especificada por la ecuación. En un curso de difusión, este punto es decisivo: antes de aprender el proceso inverso, debemos saber generar correctamente el proceso directo.

6 Interpretación visual del proceso directo

La trayectoria visual de una muestra permite observar cómo la estructura se destruye gradualmente. Al inicio se conservan trazos de techo, paredes y puerta. En tiempos intermedios todavía pueden aparecer rastros de la silueta, pero la señal ya compite con ruido de alta varianza. Al final, la imagen pierde su organización semántica.



Aplicar el proceso a varias muestras evidencia que la degradación no depende de una imagen particular. La misma agenda actúa sobre diferentes casas y produce el mismo tipo de transición: de datos estructurados a ruido dominante.



Estas visualizaciones deben leerse junto con la formulación matemática. No muestran simplemente que “la imagen se daña”. Muestran que el daño sigue una ley probabilística conocida:

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon.$$

La pérdida de estructura visual es la manifestación perceptual de una transferencia progresiva de peso desde la señal hacia el ruido.

7 Qué se aprende y qué no se aprende

El proceso directo q no contiene parámetros entrenables. La agenda β_t se fija y la distribución condicional $q(x_t | x_0)$ queda completamente determinada. Por esta razón, el proceso directo por sí solo no es un modelo generativo completo.

El aprendizaje aparece al intentar invertir la degradación. Si el proceso directo produce

$$q(x_t | x_{t-1}),$$

el modelo generativo buscará aproximar transiciones inversas de la forma

$$p_\theta(x_{t-1} | x_t).$$

Esta nota no desarrolla todavía el entrenamiento de p_θ . Su objetivo es dejar establecida la construcción probabilística que genera los datos ruidosos sobre los cuales se formulará el problema de denoising.

Observación 2 (Separación de roles). El proceso directo es fijo y conocido; el proceso inverso será aprendido. Confundir estos dos roles oscurece la arquitectura conceptual de los modelos de difusión.

8 Resumen

El proceso de difusión directa define una cadena de Markov gaussiana que transforma una muestra de datos x_0 en variables ruidosas x_t . Su transición local agrega ruido con varianza β_t , mientras que la forma cerrada permite muestrear directamente x_t condicionado en x_0 . La cantidad $\bar{\alpha}_t$ resume el efecto acumulado de la agenda de ruido y controla el intercambio entre señal y ruido.

La importancia del proceso directo no está en que genere imágenes útiles. Su valor es matemático y computacional: construye una familia de problemas de denoising bien definidos. A partir de esa familia, el siguiente paso será decidir qué debe predecir un modelo: la imagen limpia, el ruido agregado o alguna variable equivalente.

9 Preguntas de estudio

1. ¿Por qué el proceso directo se formula como una cadena de Markov?
2. ¿Qué papel cumple β_t en la transición $q(x_t | x_{t-1})$?
3. ¿Por qué $\bar{\alpha}_t$ resume el efecto acumulado de la agenda de ruido?
4. ¿Qué ventaja computacional ofrece la forma cerrada $q(x_t | x_0)$?
5. ¿Cómo se interpreta la relación señal-ruido SNR_t ?
6. ¿Por qué el proceso directo no es todavía un modelo generativo completo?
7. ¿Qué información queda disponible para el proceso inverso cuando t es grande?

10 Continuidad

El siguiente notebook partirá de esta construcción para formular el problema de denoising. Usaremos la ecuación cerrada para generar pares sintéticos (x_t, t) y estudiaremos posibles objetivos de predicción. Esa transición marca el paso desde una cadena probabilística fija hacia un modelo parametrizado capaz de aprender una aproximación del proceso inverso.