

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 03

Denoising y objetivos de entrenamiento

Curso abierto OpenCourses.AI | 2026

La difusión directa destruye estructura de forma controlada. El objetivo de denoising convierte esa destrucción conocida en una tarea supervisada para aprender a invertirla.

1 Motivación

El proceso directo de difusión, estudiado en el notebook anterior, define una familia de distribuciones condicionales $q(x_t | x_0)$. Dado un dato limpio x_0 , un tiempo t y ruido gaussiano ϵ , podemos construir una versión ruidosa x_t . Esta construcción es fija: no contiene parámetros entrenables y no genera datos nuevos por sí misma.

El paso conceptual de esta nota consiste en convertir esa corrupción conocida en un problema de aprendizaje. Si durante la construcción conocemos el ruido que fue usado, entonces podemos fabricar ejemplos supervisados sin etiquetas humanas. El modelo futuro recibirá una entrada ruidosa y un tiempo, y deberá predecir una cantidad asociada con la corrupción.

Idea clave 1 (Supervisión inducida). La difusión directa transforma un dataset no etiquetado en un conjunto de tareas supervisadas. La etiqueta no proviene de una anotación externa; proviene de la variable aleatoria ϵ que nosotros mismos muestreamos para construir x_t .

2 Del proceso directo al dato supervisado


Recordemos la forma cerrada del proceso directo:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

Esta ecuación define un mecanismo para construir triples


$$(x_0, t, \epsilon) \mapsto x_t.$$

El dato limpio x_0 se toma del dataset, el tiempo t se escoge de una distribución sobre $\{1, \dots, T\}$, el ruido ϵ se muestrea de una gaussiana estándar y x_t se calcula de manera determinista a partir de esas cantidades.



La figura resume el cambio de perspectiva. En el proceso directo, ϵ es la perturbación que degrada el dato. En el entrenamiento de denoising, esa misma variable se convierte en el objetivo supervisado. Esta inversión de roles es la razón por la cual los modelos de difusión pueden entrenarse con datasets no etiquetados.

Ejemplos supervisados: entrada (x_t, t) y objetivo ϵ



La fila superior conserva el dato limpio de referencia. La fila intermedia muestra el ruido ϵ usado en cada tiempo. La fila inferior muestra la entrada ruidosa x_t . La lectura correcta no es que el modelo vea x_0 y ϵ durante inferencia; durante entrenamiento, esas cantidades permiten construir el par supervisado $(x_t, t) \mapsto \epsilon$.

3 Tres objetivos posibles

Una vez construido x_t , existen varias formas de definir la tarea de aprendizaje. La más directa es pedir al modelo que prediga la muestra limpia:

$$f_\theta(x_t, t) \approx x_0.$$

Esta formulación es intuitiva, porque se parece a eliminar ruido de una imagen. Sin embargo, en modelos DDPM es común parametrizar el objetivo de otra manera.

La segunda posibilidad es predecir el ruido usado para construir la muestra:

$$\epsilon_\theta(x_t, t) \approx \epsilon.$$

Aunque al principio parezca menos natural, este objetivo tiene ventajas importantes. El objetivo ϵ vive en una escala conocida, está centrado y proviene siempre de una gaussiana estándar. Además, si el ruido se predice correctamente, la muestra limpia puede recuperarse algebraicamente.

La tercera lectura conecta con el score. Para la condicional gaussiana $q(x_t | x_0)$, se cumple

$$\nabla_{x_t} \log q(x_t | x_0) = -\frac{x_t - \sqrt{\bar{\alpha}_t} x_0}{1 - \bar{\alpha}_t} = -\frac{\epsilon}{\sqrt{1 - \bar{\alpha}_t}}.$$

Por tanto, conocer ϵ equivale a conocer el score condicional salvo un factor dependiente del tiempo.

Hay un matiz esencial. En entrenamiento, el modelo no recibe x_0 , sino solamente (x_t, t) . Al promediar sobre los posibles datos limpios compatibles con x_t , la predicción de ruido se relaciona con el score marginal de la distribución ruidosa $q_t(x_t)$:

$$\nabla_{x_t} \log q_t(x_t) = -\frac{1}{\sqrt{1 - \bar{\alpha}_t}} \mathbb{E}[\epsilon | x_t, t].$$

Esta ecuación anticipa la lectura por score que será estudiada más adelante. En esta nota solo necesitamos retener la idea principal: predecir ruido no es un truco computacional aislado, sino una parametrización conectada con la geometría probabilística del proceso directo.

Observación 1 (Condicional y marginal). El score condicional $\nabla_{x_t} \log q(x_t | x_0)$ usa información del dato limpio. El modelo entrenado no dispone de x_0 , por lo que su predicción se interpreta a través de una esperanza condicional dada la observación ruidosa x_t .

4 Pérdida de predicción de ruido

El objetivo que usaremos en la primera implementación de entrenamiento será la predicción de ruido. La pérdida ideal se escribe como

$$\mathcal{L}(\theta) = \mathbb{E}_{x_0, t, \epsilon} \left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2 \right].$$

La esperanza indica que el error debe promediarse sobre datos limpios, tiempos de difusión y muestras de ruido. En la práctica se aproxima con mini-lotes. Cada paso de entrenamiento tendrá la estructura

$$x_0 \longrightarrow (t, \epsilon) \longrightarrow x_t \longrightarrow \epsilon_\theta(x_t, t) \longrightarrow \|\epsilon - \epsilon_\theta(x_t, t)\|_2^2.$$

Esta pérdida no requiere etiquetas semánticas. Tampoco requiere evaluar explícitamente $p_{\text{data}}(x)$. Solo requiere poder muestrear datos del dataset, tiempos y ruido gaussiano.

Idea clave 2 (Objetivo de entrenamiento). El entrenamiento DDPM básico aprende una función que estima el ruido usado para corromper una muestra. La pérdida cuadrática mide el error entre el ruido verdadero ϵ y la predicción $\epsilon_\theta(x_t, t)$.

5 Reconstrucción algebraica del dato limpio


Si se dispone de una predicción de ruido, la forma cerrada del proceso directo puede despejarse para estimar x_0 :

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

Cuando se reemplaza $\epsilon_\theta(x_t, t)$ por el ruido verdadero ϵ , la reconstrucción coincide con x_0 , salvo errores numéricos:

$$\frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon}{\sqrt{\bar{\alpha}_t}} = x_0.$$

Reconstrucción algebraica usando el ruido verdadero



Esta figura no muestra aprendizaje. Muestra una comprobación algebraica: si el modelo llegara a predecir exactamente el ruido, entonces la información necesaria para reconstruir x_0 estaría disponible. La predicción de ruido es, por tanto, una parametrización indirecta pero suficiente para estimar el dato limpio.

6 Error de ruido y amplificación temporal

En entrenamiento real, la predicción de ruido no será exacta. Supongamos que el error de predicción es

$$\delta_t = \epsilon_\theta(x_t, t) - \epsilon.$$


Al sustituir en la fórmula de reconstrucción, se obtiene

$$\hat{x}_0 - x_0 = -\sqrt{\frac{1 - \bar{\alpha}_t}{\bar{\alpha}_t}} \delta_t.$$

La misma magnitud de error en ϵ_θ puede tener efectos distintos sobre la reconstrucción de x_0 , dependiendo del tiempo. Definimos el factor


$$A_t = \sqrt{\frac{1 - \bar{\alpha}_t}{\bar{\alpha}_t}}.$$

Este factor depende únicamente de la agenda de ruido. Cuando t es pequeño, $\bar{\alpha}_t$ es cercano a uno y A_t es bajo. Cuando t es grande, $\bar{\alpha}_t$ puede ser muy pequeño y A_t crece rápidamente.



La figura muestra por qué el tiempo debe entregarse al modelo. No todos los denoising son equivalentes: la escala del problema cambia con t . El modelo debe saber en qué nivel de ruido se encuentra para interpretar correctamente x_t .

Efecto de errores artificiales en ϵ_θ para $t = 400$




La visualización con errores artificiales ilustra la ecuación anterior. Al aumentar el error en la predicción de ruido, la reconstrucción se degrada. La degradación no es una propiedad estética aislada; responde al factor algebraico que multiplica el error δ_t .

7 Mini-lote de entrenamiento

Un mini-lote para predicción de ruido se construye repitiendo el mismo procedimiento para varias muestras. Para cada elemento del lote se escoge un dato limpio $x_0^{(i)}$, un tiempo t_i y ruido $\epsilon^{(i)}$. Luego se calcula

$$x_{t_i}^{(i)} = \sqrt{\bar{\alpha}_{t_i}} x_0^{(i)} + \sqrt{1 - \bar{\alpha}_{t_i}} \epsilon^{(i)}.$$

El lote de entrenamiento queda formado por entradas $(x_{t_i}^{(i)}, t_i)$ y objetivos $\epsilon^{(i)}$.



Esta figura es importante porque muestra la unidad computacional del entrenamiento: un mismo lote contiene niveles de ruido distintos. Por esa razón, el condicionamiento temporal no es un detalle de arquitectura; es parte de la definición del problema.

8 Resumen

En esta nota se estableció cómo el proceso directo de difusión induce un objetivo de entrenamiento:

1. La forma cerrada de $q(x_t | x_0)$ permite construir x_t directamente a partir de x_0 , t y ϵ .
2. La variable ϵ , que destruye estructura en el proceso directo, se convierte en el objetivo supervisado durante entrenamiento.
3. La predicción de ruido se entrena con una pérdida cuadrática sobre datos, tiempos y muestras gaussianas.
4. Una predicción de ruido permite despejar una estimación $\hat{x}_0$.
5. El error de predicción se amplifica por un factor dependiente del tiempo.
6. La predicción de ruido se conecta con el score condicional y, al promediar sobre x_0 , con el score marginal $q_t(x_t)$.

El resultado central es que ya no solo tenemos un proceso que agrega ruido. Tenemos una tarea optimizable: aprender una función $\epsilon_\theta(x_t, t)$ que prediga la perturbación usada para construir la muestra ruidosa.

9 Preguntas de estudio

1. ¿Por qué la difusión directa permite construir supervisión sin etiquetas humanas?
2. ¿Qué diferencia hay entre predecir x_0 y predecir ϵ ?
3. ¿Cómo se obtiene $\hat{x}_0$ a partir de una predicción de ruido?
4. ¿Por qué el tiempo t debe entregarse como entrada al modelo?
5. ¿Qué relación existe entre ϵ y el score condicional de $q(x_t | x_0)$?
6. ¿Por qué el modelo entrenado se relaciona con un score marginal y no solo con el score condicional?
7. ¿Qué representa el factor $A_t = \sqrt{(1 - \bar{\alpha}_t)/\bar{\alpha}_t}$?
8. ¿Qué información contiene un mini-lote de entrenamiento para predicción de ruido?

10 Continuidad

El siguiente paso del curso será reemplazar la función abstracta $\epsilon_\theta(x_t, t)$ por una red neuronal concreta. Para ello necesitaremos introducir una arquitectura compacta, una representación del tiempo, un optimizador y un bucle de entrenamiento. El objetivo matemático ya está definido; falta construir una familia de funciones capaz de aproximarlos.