

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 05

Muestreo iterativo y evaluación cualitativa

Curso abierto OpenCourses.AI | 2026

Una red entrenada para predecir ruido no es todavía un generador operativo. La generación aparece cuando esa predicción se inserta repetidamente en una cadena inversa que transforma ruido gaussiano en una muestra visual.

1 Motivación

El notebook anterior cerró el primer ciclo entrenable de un DDPM no condicional. Se construyó una función

$$\epsilon_{\theta}(x_t, t)$$

capaz de estimar el ruido presente en una imagen corrompida. Esa función, sin embargo, no genera una imagen por sí sola. Para obtener una muestra nueva debemos partir de ruido gaussiano y aplicar una secuencia de transiciones inversas.

Esta nota estudia esa transición conceptual: pasar de un modelo entrenado a un procedimiento de muestreo. El interés principal no es mejorar la arquitectura ni modificar la pérdida. El interés es comprender cómo se usa la predicción de ruido en cada paso, por qué el proceso debe iterarse muchas veces, cómo se interpreta una trayectoria intermedia y qué se altera cuando se cambia el esquema de muestreo.

Idea clave 1 (Generación como procedimiento). En un DDPM, el objeto entrenado es una red de denoising. El generador completo es la combinación entre esa red, una agenda de ruido y una regla de transición inversa aplicada de forma iterativa.

2 Transición inversa DDPM

Recordemos el proceso directo:

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

El modelo entrenado aproxima el ruido de corrupción:

$$\epsilon_{\theta}(x_t, t) \approx \epsilon.$$

A partir de esa predicción se define una media para la transición inversa:

$$\mu_{\theta}(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t) \right).$$


La varianza posterior usada en el paso inverso es

$$\tilde{\beta}_t = \beta_t \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}.$$


Por tanto, para $t > 1$, el paso de muestreo se escribe como

$$x_{t-1} = \mu_\theta(x_t, t) + \sqrt{\tilde{\beta}_t} z, \quad z \sim \mathcal{N}(0, I).$$

Cuando $t = 1$, se omite la perturbación gaussiana final. En la implementación computacional del curso los índices van de 0 a $T - 1$, pero la lectura matemática conserva la notación usual $1, \dots, T$.



La figura separa las dos partes del paso. La media $\mu_\theta(x_t, t)$ concentra el efecto aprendido: depende de la estimación de ruido producida por la red. El término $\sqrt{\tilde{\beta}_t} z$ conserva el carácter probabilístico de la cadena. Esta separación es esencial para interpretar el muestreo: no estamos aplicando un filtro determinista fijo, sino una transición gaussiana cuyo centro depende del modelo entrenado.




3 Coeficientes de la actualización

La expresión de la media inversa puede parecer compacta, pero contiene coeficientes con comportamientos distintos a lo largo del tiempo:

$$\frac{1}{\sqrt{\alpha_t}}, \quad \frac{\beta_t}{\sqrt{\alpha_t(1-\bar{\alpha}_t)}}, \quad \sqrt{\tilde{\beta}_t}.$$


El primero multiplica el estado actual x_t . El segundo controla cuánto se resta de la predicción de ruido. El tercero determina la escala de la perturbación gaussiana añadida en la transición.



Visualizar estos coeficientes evita una interpretación demasiado informal del muestreo. La red no “limpia” la imagen de manera arbitraria. Su predicción se inserta en una fórmula precisa, modulada por la agenda β_t , por α_t y por el producto acumulado $\bar{\alpha}_t$.

4 Recuperación del modelo entrenado

El notebook reutiliza el checkpoint producido por el modelo no condicional del notebook 04. Esto separa entrenamiento y muestreo. Si volviéramos a entrenar en cada ejecución, la lectura del notebook se mezclaría con variaciones del optimizador, inicialización y tiempo de cómputo. Al cargar un modelo fijo, el análisis se concentra en la cadena inversa.




La curva de pérdida no se usa aquí como argumento central de calidad. Su papel es documentar que el modelo cargado proviene de un entrenamiento efectivo de predicción de ruido. La calidad del muestreo debe juzgarse aparte, porque depende de la acumulación de muchos pasos y no solo de una pérdida local.

5 Reconstrucción puntual

Antes de estudiar una trayectoria completa conviene observar un solo paso. Si conocemos una imagen limpia x_0 , podemos corromperla hasta un tiempo t , pedir al modelo que estime el ruido y reconstruir una aproximación de la muestra limpia:

$$\hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

También podemos calcular la media $\mu_\theta(x_t, t)$ que se usaría para avanzar hacia x_{t-1} .



Esta figura no muestra generación libre. Muestra los objetos internos de una transición: dato limpio, dato ruidoso, ruido real, ruido predicho, estimación $\hat{x}_0$ y media inversa. Su función pedagógica es fijar qué calcula la red y cómo esa salida se convierte en una transición probabilística.


Observación 1 (Reconstrucción local y muestreo global). Una reconstrucción local razonable no garantiza automáticamente una muestra final de alta calidad. El muestreo completo exige que la red produzca predicciones consistentes durante cientos o miles de transiciones encadenadas.

6 Trayectoria desde ruido

La generación libre parte de una variable

$$x_T \sim \mathcal{N}(0, I)$$


y aplica el paso inverso hasta llegar a x_0 . El notebook guarda estados intermedios para observar la evolución.



La estructura no aparece de golpe. Durante gran parte de la trayectoria, las muestras siguen pareciendo ruido con leves tendencias espaciales. Cerca de los tiempos finales emergen trazos más coherentes: techos, bases, puertas o contornos parciales. Esta progresión ilustra una propiedad central de los modelos de difusión: la muestra final es el resultado acumulado de muchos pasos pequeños.

7 Variabilidad por semilla

En un modelo no condicional, cambiar la semilla inicial cambia la muestra, pero no cambia la categoría objetivo. No hay una etiqueta que diga qué generar; el modelo solo ha aprendido una distribución marginal de casas. Por eso la comparación entre semillas debe leerse como diversidad dentro de una misma distribución aprendida.



La variabilidad observada es deseable hasta cierto punto. Si todas las semillas produjeran la misma imagen, el procedimiento estaría colapsando hacia un prototipo. Si muchas semillas produjeran trazos sin estructura, el modelo no estaría representando adecuadamente la distribución de datos. El comportamiento buscado es intermedio: diversidad visual con rasgos consistentes de la categoría.

8 Costo de muestreo y aproximación determinista

La cadena inversa DDPM completa usa una evaluación del modelo por cada tiempo. Con $T = 1000$, eso implica mil llamadas a ϵ_θ por muestra. Para explorar el efecto de reducir costo, el notebook compara esa cadena completa con una aproximación determinista por saltos. En dicha aproximación se estima $\hat{x}_0$ y se proyecta a un tiempo anterior $s < t$:

$$x_s = \sqrt{\bar{\alpha}_s} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_s} \epsilon_\theta(x_t, t).$$

Cadena inversa DDPM frente a aproximación determinista de bajo costo



Esta comparación debe interpretarse con precisión. No se cambia únicamente el número de evaluaciones: también cambia la regla de actualización. Por tanto, el deterioro visual no puede atribuirse solo a usar menos pasos. Lo que se observa es un compromiso conjunto entre costo computacional y fidelidad al procedimiento probabilístico original.

Idea clave 2 (Costo y fidelidad). Reducir el número de evaluaciones puede abaratar la generación, pero exige cambiar el esquema numérico o la regla de muestreo. En modelos de difusión, costo y calidad no son variables independientes.

9 Limitaciones del análisis

El análisis del notebook es cualitativo y deliberadamente acotado. Sus principales límites son:

1. El modelo sigue siendo no condicional; no existe control semántico explícito.
2. La evaluación visual se realiza sobre imágenes de baja resolución.
3. La comparación de bajo costo mezcla reducción de evaluaciones con cambio de actualización.
4. No se introducen métricas cuantitativas como FID, precisión de clasificación o diversidad estadística.

5. No se estudian todavía alternativas modernas de muestreo acelerado.

Estas limitaciones son aceptables para el objetivo del bloque. Antes de introducir condicionamiento o guidance, era necesario entender qué hace la cadena inversa en el caso no condicional.

10 Resumen

Esta nota cerró el primer bloque conceptual del curso. Ya no solo tenemos una red entrenada para predecir ruido; tenemos un procedimiento generativo completo. La cadena inversa DDPM combina la predicción $\epsilon_\theta(x_t, t)$, la media $\mu_\theta(x_t, t)$, la varianza posterior $\tilde{\beta}_t$ y una secuencia temporal de transiciones.

El resultado central es que la generación no ocurre en un único paso. La estructura visual emerge gradualmente al iterar una regla probabilística que usa la red entrenada en cada tiempo. La comparación entre semillas muestra diversidad no condicional, mientras que la comparación con una aproximación determinista evidencia que abaratar el muestreo debe hacerse con cuidado.

Con esto queda completo el primer recorrido DDPM: datos, ruido, difusión directa, objetivo de denoising, entrenamiento y muestreo inverso.

11 Preguntas de estudio

1. ¿Qué parte de la actualización inversa depende de ϵ_θ y qué parte depende solo de la agenda de ruido?
2. ¿Por qué el paso inverso incluye una perturbación gaussiana salvo en el último tiempo?
3. ¿Qué diferencia hay entre estimar $\hat{x}_0$ en un tiempo aislado y generar una muestra desde x_T ?
4. ¿Por qué distintas semillas producen imágenes distintas aunque el modelo sea el mismo?
5. ¿Qué se pierde cuando se reemplaza la cadena inversa DDPM por una aproximación determinista con saltos amplios?
6. ¿Por qué el análisis de muestreo debe separarse del análisis de entrenamiento?
7. ¿Qué aspectos de este notebook cambiarían al introducir una etiqueta de clase?

12 Continuidad

El siguiente bloque del curso debe abandonar la distribución marginal de una sola categoría. Al introducir varias clases de QuickDraw, el dataset dejará de representar una única distribución de casas y pasará a formularse como una mezcla de distribuciones. Esa transición motivará los modelos condicionales: no solo queremos generar una muestra plausible, sino controlar qué tipo de muestra se genera.