

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 06

Mezclas de distribuciones y estructura semántica

Curso abierto OpenCourses.AI | 2026

Cuando un dataset contiene varias clases, la distribución de imágenes deja de ser una sola nube visual. La etiqueta induce una descomposición de la marginal en componentes condicionales, y esa descomposición es la puerta de entrada al control generativo.

1 Motivación

Los notebooks anteriores estudiaron un DDPM no condicional sobre una sola categoría de QuickDraw. Esa restricción fue útil: permitió concentrarse en la distribución de datos, el ruido gaussiano, la difusión directa, el objetivo de predicción de ruido y la cadena inversa sin introducir variables semánticas adicionales.

El notebook 06 cambia deliberadamente el objeto estadístico. El dataset ya no contiene solo casas, sino varias clases: *house*, *cat*, *tree*, *fish* y *apple*. Todas las imágenes siguen viviendo en el mismo espacio vectorial, pero ahora existe una variable de clase y . El problema generativo deja de ser únicamente aproximar una distribución marginal de imágenes y pasa a involucrar una distribución conjunta.

Esta nota formaliza esa transición. El objetivo no es entrenar todavía un modelo condicional, sino precisar por qué será necesario. Antes de introducir una arquitectura que reciba etiquetas, conviene entender qué estructura estadística aporta la etiqueta.

Idea clave 1 (De marginal a familia condicional). Un dataset etiquetado permite leer la distribución de datos de dos maneras: como una marginal $p_{\text{data}}(x)$, que mezcla todas las clases, o como una familia de distribuciones condicionales $p_{\text{data}}(x \mid y = k)$, una por componente semántica.

2 Dataset etiquetado

Sea

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N, \quad x_i \in \mathbb{R}^d, \quad y_i \in \{1, \dots, K\}.$$

En el curso, $d = 784$, porque cada imagen de QuickDraw se representa como una matriz 28×28 reorganizada como vector. El número de clases es $K = 5$.

La distribución empírica conjunta puede escribirse como una suma de masas puntuales:

$$\hat{p}(x, y) = \frac{1}{N} \sum_{i=1}^N \delta(x - x_i) \mathbf{1}\{y = y_i\}.$$


Esta expresión no pretende ser un modelo suave de densidad. Su función es formalizar lo que realmente tenemos: una colección finita de observaciones. Cada par (x_i, y_i) aporta simultáneamente una imagen y una etiqueta.

Para cada clase k , definimos

$$N_k = \sum_{i=1}^N \mathbf{1}\{y_i = k\}, \quad \hat{\pi}_k = \frac{N_k}{N}.$$

El término $\hat{\pi}_k$ es el prior empírico de clase. Indica la probabilidad de observar la clase k si se muestrea uniformemente un ejemplo del dataset.

Formulación empírica de una mezcla etiquetada



La etiqueta no cambia el espacio $x_t \in \mathbb{R}^{784}$; cambia la familia de distribuciones que el modelo puede seleccionar.

La figura resume el punto central. Las etiquetas no modifican el espacio de imágenes: todas las clases siguen en $\mathbb{R}^{784}$. Lo que modifican es la lectura probabilística del dataset. Con etiquetas podemos separar frecuencia de clase, geometría visual de cada componente y objetivo de aprendizaje.

3 Distribución marginal como mezcla

La distribución empírica condicional de la clase k se escribe como


$$\hat{p}_k(x) = \hat{p}(x | y = k) = \frac{1}{N_k} \sum_{i: y_i = k} \delta(x - x_i).$$

La distribución marginal de imágenes se obtiene al sumar las componentes ponderadas por sus priors:

$$\hat{p}(x) = \sum_{k=1}^K \hat{\pi}_k \hat{p}_k(x).$$

Esta ecuación es el puente conceptual hacia los modelos condicionales. Si un modelo ignora y , aprende una aproximación a la mezcla total. Si el modelo recibe y , puede aprender una familia de distribuciones seleccionables.

Muestras por componente empírica



La visualización de muestras por clase muestra que las componentes son distinguibles, pero no por vivir en espacios distintos. Todas son imágenes binarias o casi binarias de 28×28 . La diferencia está en las regularidades geométricas de los trazos: contornos triangulares en casas, orejas en gatos, copa y tronco en árboles, cuerpo alargado en peces y forma cerrada con tallo en manzanas.


Observación 1 (Mezcla balanceada). El subconjunto usado en el notebook es casi balanceado. Esto reduce un factor de confusión: si una clase dominara la muestra, un modelo no condicional tendería a verla con mayor frecuencia. Aquí el interés principal no es el desbalance, sino la coexistencia de componentes semánticas en la misma marginal.

4 Prior empírico de clase

El prior empírico se estima con una frecuencia relativa. En el dataset del notebook:

$$\hat{\pi}_k = \frac{N_k}{N} \approx 0.2 \quad \text{para cada clase.}$$

En un modelo no condicional, este prior afecta indirectamente el muestreo. Si entrenamos sobre la marginal, el modelo no recibe una instrucción de clase; por tanto, las clases generadas deberían aparecer de acuerdo con la mezcla aprendida.




El prior no describe la forma de las imágenes. Describe la proporción de componentes. Esta separación entre frecuencia y geometría es importante: dos clases pueden tener priors similares y, aun así, ocupar regiones visualmente diferentes del espacio.

5 Momentos empíricos por clase

Una manera básica de resumir cada componente es calcular su media y varianza por pixel:

$$\hat{\mu}_k = \frac{1}{N_k} \sum_{i:y_i=k} x_i, \quad \hat{\sigma}_k^2 = \frac{1}{N_k} \sum_{i:y_i=k} (x_i - \hat{\mu}_k)^2.$$

Estos objetos no deben confundirse con imágenes generadas. La media es un resumen de estructura recurrente; la varianza identifica regiones donde los trazos cambian más dentro de la clase.



La media de cada clase evidencia una forma prototípica, pero borrosa. Esa borrosidad no es un defecto: aparece porque promediamos muchas maneras distintas de dibujar una misma categoría. La varianza, por su parte, marca las zonas donde hay mayor diversidad intracase. En términos generativos, un modelo útil no debe reproducir solo la media; debe capturar la variabilidad alrededor de ella.

6 Proyección de baja dimensión


El espacio original es de alta dimensión. Para observar la mezcla en dos dimensiones, el notebook usa PCA sobre una muestra balanceada. Si $X \in \mathbb{R}^{m \times d}$ es la matriz de imágenes vectorizadas y centradas, la descomposición en valores singulares es

$$X = U\Sigma V^\top.$$

Tomando los dos primeros vectores singulares derechos,

$$V_2 = [v_1, v_2], \quad Z = XV_2,$$

obtenemos una representación bidimensional $Z \in \mathbb{R}^{m \times 2}$.



La proyección muestra separación parcial, no particiones perfectas. Esto es esperable. PCA no busca maximizar separación de clases; busca direcciones de máxima varianza global. Aun así, la figura deja ver que las clases inducen regiones con estructura. Para el curso, lo importante no es que PCA clasifique, sino que permite observar que la marginal contiene múltiples componentes.

Observación 2 (Límite de la visualización). Una proyección bidimensional puede ocultar relaciones importantes del espacio original. La superposición de puntos en PCA no implica que las clases sean indistinguibles en $\mathbb{R}^{784}$, y la separación visual tampoco implica que el problema generativo esté resuelto.


7 Muestreo marginal y muestreo condicional

Antes de entrenar un modelo, podemos comparar dos procedimientos empíricos:

$$x \sim \hat{p}(x) \quad \text{y} \quad x \sim \hat{p}(x \mid y = k).$$

El primero ignora la etiqueta y produce muestras de la mezcla. El segundo fija una componente y extrae muestras solo de esa clase.

Muestreo empírico desde la mezcla y desde una componente



Esta comparación no es generación aprendida. Es una demostración de los objetos que el modelo deberá aproximar. El muestreo marginal responde “dame una imagen plausible del dataset”. El muestreo condicional responde “dame una imagen plausible de esta clase”. Esa diferencia es exactamente la que se busca trasladar al modelo generativo.


8 Difusión directa sobre varias componentes

La difusión directa no necesita cambiar al pasar de una clase a varias. Para cualquier imagen x_0 , independientemente de su etiqueta, se define

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

La etiqueta no altera la forma de $q(x_t \mid x_0)$. Lo que cambia es la distribución de donde proviene x_0 : antes venía de una sola componente; ahora viene de una mezcla.

Difusión directa aplicada a distintas componentes



A tiempos bajos, la estructura semántica todavía es visible. A tiempos altos, las diferencias de clase se vuelven menos evidentes para un observador humano, aunque cada ejemplo de entrenamiento conserva su etiqueta si decidimos pasarla al modelo. Esto prepara el objetivo condicional: la red debe aprender a remover ruido no solo con x_t y t , sino también con y .

9 Objetivo no condicional y objetivo condicional

Si entrenamos un DDPM no condicional sobre el dataset multicategoría, el objetivo queda promediado sobre la mezcla:

$$\mathcal{L}_{\text{marg}}(\theta) = \mathbb{E}_{y \sim \hat{\pi}, x_0 \sim \hat{p}(x|y), t, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(x_t, t)\|_2^2 \right].$$

La red recibe una imagen ruidosa y un tiempo, pero no recibe la clase. Por tanto, aprende una función compartida para toda la mezcla.

El objetivo condicional introduce explícitamente la etiqueta:

$$\mathcal{L}_{\text{cond}}(\theta) = \mathbb{E}_{y \sim \hat{\pi}, x_0 \sim \hat{p}(x|y), t, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(x_t, t, y)\|_2^2 \right].$$

La modificación notacional es pequeña, pero la consecuencia generativa es grande. El modelo deja de representar solo una marginal y pasa a representar una familia de distribuciones condicionadas.

Idea clave 2 (Control generativo). El condicionamiento no consiste en cambiar el espacio de imágenes ni el proceso directo de ruido. Consiste en permitir que la red use una variable adicional para seleccionar qué componente de la mezcla debe reconstruir durante el proceso inverso.

10 Limitaciones del análisis

El notebook y esta nota se mantienen en un nivel previo al entrenamiento condicional. Sus límites principales son:

1. No se entrena todavía una red con etiquetas.
2. Las clases se estudian con visualizaciones empíricas simples.
3. PCA se usa como herramienta exploratoria, no como modelo generativo ni como prueba de separabilidad.
4. El dataset está balanceado de forma deliberada; no se estudian efectos de desbalance.
5. No se evalúa aún si un modelo condicional puede obedecer la condición durante el muestreo.

Estas limitaciones son convenientes para la secuencia del curso. El objetivo de este bloque es aislar la estructura estadística que justifica el condicionamiento.

11 Resumen

Esta nota introdujo la transición desde una distribución visual única hacia una mezcla etiquetada. El objeto central ya no es solo $p_{\text{data}}(x)$, sino la distribución conjunta $p_{\text{data}}(x, y)$ y sus condicionales $p_{\text{data}}(x \mid y = k)$.

La formulación empírica muestra que la marginal puede escribirse como

$$\hat{p}(x) = \sum_{k=1}^K \hat{\pi}_k \hat{p}_k(x).$$

Esta ecuación resume el sentido estadístico del notebook. Ignorar y obliga a aprender la mezcla completa. Usar y permite formular una familia de distribuciones seleccionables.

Las visualizaciones de componentes, priors, momentos, PCA y difusión directa muestran el mismo hecho desde ángulos distintos: las clases comparten el mismo espacio vectorial, pero inducen estructuras semánticas diferentes. Por eso el siguiente paso natural es introducir un modelo de difusión condicional.

12 Preguntas de estudio

1. ¿Qué diferencia hay entre la distribución conjunta $\hat{p}(x, y)$ y la marginal $\hat{p}(x)$?
2. ¿Por qué la marginal puede escribirse como una mezcla de distribuciones condicionales?
3. ¿Qué representa $\hat{\pi}_k$ y por qué no describe la geometría visual de la clase?
4. ¿Por qué la media empírica de una clase no debe interpretarse como una imagen generada?

5. ¿Qué información aporta PCA y qué información puede ocultar?
6. ¿Por qué el proceso directo $q(x_t | x_0)$ no necesita cambiar al introducir etiquetas?
7. ¿Qué cambia matemáticamente al pasar de $\epsilon_\theta(x_t, t)$ a $\epsilon_\theta(x_t, t, y)$?

13 Continuidad

El siguiente notebook introduce el primer DDPM condicional del curso. La arquitectura deberá incorporar una representación de la etiqueta y , por ejemplo mediante embeddings de clase, y el muestreo deberá permitir fijar una clase objetivo. La pregunta dejará de ser si el modelo puede generar una imagen plausible de la mezcla y pasará a ser si puede generar una imagen plausible de una componente solicitada.