

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 08

Classifier-free guidance

Curso abierto OpenCourses.AI | 2026

Classifier-free guidance convierte un modelo condicional en un generador con control de intensidad. La red aprende a predecir ruido con condición presente y con condición ausente; durante el muestreo se amplifica la diferencia entre ambas predicciones.

1 Motivación

El notebook 07 introdujo modelos de difusión condicionales. Allí la red de denoising recibe una etiqueta discreta y y aprende una función

$$\epsilon_{\theta}(x_t, t, y).$$

Con esta modificación, el modelo puede generar muestras asociadas a una clase solicitada. Sin embargo, esa formulación todavía no incorpora un parámetro explícito para regular la fuerza de la condición durante el muestreo.

Classifier-free guidance responde a esa necesidad sin entrenar un clasificador externo. La idea es entrenar una misma red para operar en dos modos: uno condicional, donde recibe la etiqueta real, y otro no condicional, donde recibe un símbolo que representa ausencia de condición. El control aparece después, durante el muestreo, al combinar ambas predicciones.

El punto central es que la condición no solo selecciona una clase. También induce una dirección en el espacio de predicciones de ruido. Guidance consiste en moverse más o menos en esa dirección.

Idea clave 1 (Control de intensidad). En un DDPM condicional simple, la etiqueta y selecciona una distribución objetivo. En classifier-free guidance, un parámetro adicional w regula cuánto se amplifica la influencia de esa etiqueta durante la cadena inversa.

2 Condición nula y entrenamiento

Sea un dataset etiquetado

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N, \quad y_i \in \{1, \dots, K\}.$$

Para introducir classifier-free guidance, extendemos el espacio de condiciones:

$$\mathcal{C} = \{1, \dots, K, \emptyset\}.$$

El símbolo $\emptyset$ no es una clase adicional del dataset. Es una marca computacional que indica ausencia de condición. En la implementación del notebook, si las clases reales se indexan como $0, \dots, K-1$, entonces la condición nula se representa con el índice K .

Durante entrenamiento, la condición usada por la red se obtiene mediante una variable aleatoria:

$$c = \begin{cases} y, & \text{con probabilidad } 1 - p_{\text{drop}}, \\ \emptyset, & \text{con probabilidad } p_{\text{drop}}. \end{cases}$$

El hiperparámetro p_{drop} controla la fracción de ejemplos en los que se elimina la etiqueta. Si es demasiado pequeño, la red puede aprender mal el modo no condicional. Si es demasiado grande, se reduce la frecuencia con la que observa condiciones reales. En el experimento se usa $p_{\text{drop}} = 0.15$, un valor razonable para preservar ambos modos.

El proceso directo sigue siendo el mismo:

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$


La pérdida de entrenamiento es

$$\mathcal{L}_{\text{cfg}}(\theta) = \mathbb{E} \left[\|\epsilon - \epsilon_{\theta}(x_t, t, c)\|_2^2 \right].$$

Esta ecuación conserva la forma de predicción de ruido de DDPM. La diferencia es que el argumento condicional c puede ser una clase real o el símbolo nulo.

Classifier-free guidance

Entrenar con condición presente y ausente permite amplificar la dirección semántica durante el muestreo.



La figura organiza el método en tres partes. Primero se entrena con condición aleatoriamente presente o ausente. Luego, durante el muestreo, la misma red se evalúa dos veces para el mismo x_t y el mismo t . Finalmente, esas dos predicciones se interpretan geométricamente como puntos o vectores en el espacio de predicción de ruido.

3 Predicción condicional y predicción nula

Durante el muestreo, se fija una etiqueta deseada y . Para cada estado ruidoso x_t , la red se evalúa en dos modos:

$$\epsilon_{\text{cond}} = \epsilon_{\theta}(x_t, t, y), \quad \epsilon_{\text{null}} = \epsilon_{\theta}(x_t, t, \emptyset).$$

La primera predicción usa información semántica explícita. La segunda predicción aproxima el comportamiento no condicional aprendido por la misma red. Compararlas tiene sentido porque comparten parámetros, arquitectura, agenda de ruido y representación temporal.

Si ambas predicciones fueran idénticas para todo x_t , entonces la condición no estaría alterando el denoising. Cuando difieren, el vector


$$\epsilon_{\text{cond}} - \epsilon_{\text{null}}$$

puede leerse como una dirección asociada a la condición solicitada.

Observación 1 (No hay clasificador externo). El término “classifier-free” indica que no se usa un clasificador separado para orientar la generación. La orientación se obtiene comparando dos evaluaciones de la misma red de difusión.

En el notebook se muestra una comparación puntual entre reconstrucción con condición presente y reconstrucción con condición nula.

Reconstrucción con condición presente y condición nula



Esta figura debe interpretarse con cuidado. En una reconstrucción de una imagen real, especialmente si x_t todavía conserva señal visual, las salidas con condición y sin condición pueden parecer cercanas. Classifier-free guidance no depende de que una sola reconstrucción puntual cambie de forma dramática. Su efecto se acumula paso a paso durante la cadena inversa.

4 Combinación guiada

La predicción guiada se define como

$$\epsilon_{\text{cfg}} = \epsilon_{\text{cond}} + w(\epsilon_{\text{cond}} - \epsilon_{\text{null}}), \quad w \geq 0.$$

En esta convención, $w = 0$ recupera la predicción condicional ordinaria:

$$\epsilon_{\text{cfg}} = \epsilon_{\text{cond}}.$$

Si $w > 0$, la predicción se desplaza más allá de ϵ_{cond} en la dirección que separa la predicción condicional de la predicción nula.

El paso inverso DDPM usa esta predicción en la media:

$$\mu_{\theta}^{\text{cfg}}(x_t, t, y) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \alpha_t}} \epsilon_{\text{cfg}} \right).$$

Para $t > 1$, el paso completo conserva la perturbación gaussiana usual:

$$x_{t-1} = \mu_{\theta}^{\text{cfg}}(x_t, t, y) + \sqrt{\tilde{\beta}_t} z, \quad z \sim \mathcal{N}(0, I).$$


Por tanto, classifier-free guidance no redefine la difusión directa ni elimina la naturaleza estocástica del muestreo. Solo reemplaza la predicción de ruido usada para calcular la media del paso inverso.

Idea clave 2 (Dirección semántica). El término $\epsilon_{\text{cond}} - \epsilon_{\text{null}}$ no es una etiqueta ni una probabilidad. Es una diferencia entre dos predicciones de ruido. Su papel es actuar como dirección de ajuste semántico dentro del procedimiento inverso.

5 Evidencia experimental

El experimento usa las cinco clases de QuickDraw ya introducidas: *house*, *cat*, *tree*, *fish* y *apple*. La red tiene 1,751,105 parámetros entrenables, usa $T = 500$ pasos de difusión y entrena con 6000 muestras por clase. El checkpoint almacena pesos, configuración, historial de pérdida y el índice de condición nula.

Entrenamiento de $\epsilon_{\theta}(x_t, t, c)$ con condición nula



La pérdida decrece de forma estable porque la red aprende a predecir ruido tanto en modo condicional como en modo nulo. Igual que en los notebooks previos, la curva de pérdida no debe confundirse con una métrica perceptual completa. Es una señal de ajuste del objetivo supervisado inducido por el proceso directo.

Una consecuencia del entrenamiento con $\emptyset$ es que el modelo puede generar sin clase explícita:

$$x_T \sim \mathcal{N}(0, I), \quad x_{t-1} \sim p_\theta(x_{t-1} \mid x_t, \emptyset).$$

Muestras con condición nula




Estas muestras no tienen una etiqueta solicitada. Representan el modo marginal aprendido por la red dentro del mismo modelo que luego se usará para generar con guidance. Este punto es importante: el modo no condicional no proviene de otro entrenamiento.

6 Efecto del peso de guidance

La visualización más importante del notebook fija el mismo ruido inicial por clase y varía w . De esta forma se controla la fuente aleatoria y se observa principalmente el efecto del parámetro de guidance.

Mismo ruido inicial por clase, distinto peso de guidance



El efecto no debe interpretarse como una mejora monótona garantizada. En algunas clases, aumentar w refuerza rasgos visuales reconocibles. En otras, puede endurecer trazos, reducir diversidad o producir artefactos. El valor adecuado de w depende del modelo, del dataset, de la agenda de ruido y del tipo de condición.

En modelos grandes de texto a imagen, este compromiso suele describirse como una tensión entre fidelidad a la condición y diversidad. En este notebook aparece de manera sencilla: valores mayores pueden hacer que la clase sea más evidente, pero también pueden empujar la muestra hacia formas menos naturales.

7 Diversidad bajo una condición fija

Guidance no convierte la generación en un proceso determinista de una sola salida por clase. Si se fija una clase y se cambian las semillas iniciales, el modelo sigue produciendo variantes:

$$x_T^{(j)} \sim \mathcal{N}(0, I), \quad x_0^{(j)} \sim p_\theta^{\text{cfg}}(x_0 \mid y, w).$$

Variabilidad para la clase house



La figura compara varias muestras de la clase *house* con dos pesos de guidance. Con $w = 0$, la condición está presente pero no se amplifica. Con $w = 1.5$, la estructura de casa tiende a hacerse más consistente. La comparación también advierte una consecuencia: al aumentar guidance, las muestras pueden volverse más parecidas entre sí.

8 Limitaciones

Classifier-free guidance es un mecanismo de muestreo, no una solución universal a los problemas de modelado. Si la red no aprende bien el modo condicional, la predicción ϵ_{cond} será débil. Si no aprende bien el modo nulo, la diferencia $\epsilon_{\text{cond}} - \epsilon_{\text{null}}$ será poco fiable. Además, cada paso de muestreo guiado requiere dos evaluaciones de la red, lo cual aumenta el costo computacional frente al muestreo condicional simple.

También conviene notar que el símbolo $\emptyset$ debe aparecer durante entrenamiento. No es correcto tomar un modelo condicional ordinario ya entrenado y esperar que entienda una condición nula que nunca observó.

9 Resumen

Esta nota formalizó classifier-free guidance en el contexto de un DDPM de predicción de ruido. El entrenamiento modifica la distribución de condiciones observadas por la red:

$$c \in \{1, \dots, K, \emptyset\}.$$

La pérdida sigue siendo una MSE de predicción de ruido:

$$\mathcal{L}_{\text{cfg}}(\theta) = \mathbb{E} \left[\|\epsilon - \epsilon_\theta(x_t, t, c)\|_2^2 \right].$$

La diferencia conceptual aparece durante el muestreo:

$$\epsilon_{\text{cfg}} = \epsilon_\theta(x_t, t, y) + w [\epsilon_\theta(x_t, t, y) - \epsilon_\theta(x_t, t, \emptyset)].$$

El parámetro w regula cuánto se amplifica la diferencia entre el modo condicional y el modo nulo. Así, el curso pasa de generación condicional por etiqueta a generación guiada con control de intensidad.

10 Preguntas de estudio

1. ¿Por qué la condición nula $\emptyset$ no debe interpretarse como una clase del dataset?
2. ¿Qué papel cumple p_{drop} durante el entrenamiento?
3. ¿Por qué classifier-free guidance requiere dos evaluaciones de la misma red en cada paso de muestreo?
4. ¿Qué representa el término $\epsilon_{\text{cond}} - \epsilon_{\text{null}}$?
5. ¿Qué ocurre cuando $w = 0$ bajo la convención usada en esta nota?
6. ¿Por qué valores altos de w pueden reducir diversidad o introducir artefactos?
7. ¿Qué aumenta en costo computacional al usar classifier-free guidance frente a muestreo condicional simple?

11 Continuidad

Con classifier-free guidance se cierra el primer bloque práctico de DDPM discreto: ruido directo, denoising, muestreo, condicionamiento y control de intensidad. El siguiente paso conceptual es conectar la predicción de ruido con la noción de score. Esa transición permite interpretar el denoising no solo como una tarea supervisada, sino como una aproximación a campos de dirección asociados a la densidad de datos.