

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 09

Score matching e intuición geométrica

Curso abierto OpenCourses.AI | 2026

La predicción de ruido en modelos de difusión puede leerse como una forma de estimar campos score. Esta lectura convierte el denoising en geometría: aprender direcciones que apuntan hacia regiones de mayor densidad.

1 Motivación

Los notebooks anteriores construyeron modelos DDPM desde una perspectiva operativa: agregar ruido, entrenar una red para predecirlo y recorrer una cadena inversa. Esa ruta es suficiente para implementar modelos generativos, pero no explica completamente qué tipo de objeto geométrico se está aprendiendo.

El concepto de score permite hacer ese puente. Para una densidad diferenciable $p(x)$, el score se define como

$$s(x) = \nabla_x \log p(x).$$

Este campo vectorial no entrega el valor de la densidad, sino la dirección local de incremento del logaritmo de la densidad. En términos geométricos, si una partícula está en una región de baja densidad, el score indica una dirección local hacia regiones más probables.

La importancia para difusión es directa: cuando una red aprende a remover ruido gaussiano, también aprende información sobre cómo desplazarse hacia la distribución de datos. En imágenes reales este campo vive en espacios de dimensión muy alta; por eso la nota usa un ejemplo bidimensional, donde el campo se puede dibujar y verificar.

Idea clave 1 (Score). El score no es la densidad $p(x)$. Es el gradiente de $\log p(x)$. Por tanto, codifica direcciones locales de cambio de densidad, no probabilidades normalizadas.

2 Densidad y campo score

Consideremos una distribución con densidad $p : \mathbb{R}^d \rightarrow \mathbb{R}_+$. Si p es diferenciable y positiva en la región de interés, su score es

$$\nabla_x \log p(x) = \frac{\nabla_x p(x)}{p(x)}.$$

La normalización por $p(x)$ tiene una consecuencia importante: el score describe variación relativa de densidad. Dos regiones con valores de densidad muy distintos pueden tener scores comparables si su variación relativa es similar.

Otra consecuencia útil es que una constante de normalización no cambia el score. Si $p(x) = \tilde{p}(x)/Z$, entonces


$$\nabla_x \log p(x) = \nabla_x \log \tilde{p}(x),$$

porque $\log Z$ no depende de x . Esta propiedad explica por qué los métodos basados en score pueden trabajar con información local de la densidad sin modelar necesariamente su valor normalizado.

En el notebook usamos una mezcla gaussiana bidimensional:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x; \mu_k, \sigma_0^2 I), \quad x \in \mathbb{R}^2.$$

Esta distribución tiene tres regiones de alta densidad. Es suficientemente simple para calcular el score exacto y suficientemente rica para mostrar que el campo no apunta siempre hacia un único centro.



La figura muestra muestras empíricas y curvas de densidad. Aunque el ejemplo es sintético, reproduce una dificultad conceptual de los datos reales: la distribución no ocupa todo el espacio de manera uniforme; se concentra en regiones estructuradas.

3 Score de una mezcla gaussiana

Para una mezcla, el score tiene una forma cerrada en términos de responsabilidades. Definamos

$$r_k(x) = \frac{\pi_k \mathcal{N}(x; \mu_k, \sigma_0^2 I)}{\sum_{j=1}^K \pi_j \mathcal{N}(x; \mu_j, \sigma_0^2 I)}.$$

El término $r_k(x)$ mide cuánto contribuye la componente k a explicar el punto x . Para cada componente gaussiana isotrópica,


$$\nabla_x \log \mathcal{N}(x; \mu_k, \sigma_0^2 I) = \frac{\mu_k - x}{\sigma_0^2}.$$

Por tanto, el score de la mezcla es

$$\nabla_x \log p(x) = \sum_{k=1}^K r_k(x) \frac{\mu_k - x}{\sigma_0^2}.$$

Esta expresión debe leerse como un promedio ponderado de direcciones hacia los centros de las componentes. Cerca de un modo, una responsabilidad domina. Entre modos, varias responsabilidades compiten.

El ruido suaviza la densidad y modifica el campo $\nabla_x \log p_\sigma(x)$



La figura compara el score de la distribución limpia con el score de una distribución perturbada. Al añadir ruido, la densidad se suaviza: las regiones de alta probabilidad se ensanchan y el campo se vuelve menos abrupto. Esta idea anticipa por qué los modelos de difusión trabajan con múltiples niveles de ruido.

4 Denoising score matching

En datos reales no conocemos $p_{\text{data}}(x)$, y por tanto no podemos calcular $\nabla_x \log p_{\text{data}}(x)$. Denoising score matching evita este obstáculo perturbando muestras conocidas:

$$x_\sigma = x_0 + \sigma\epsilon, \quad x_0 \sim p_{\text{data}}, \quad \epsilon \sim \mathcal{N}(0, I).$$

La distribución condicional de x_σ dado x_0 es

$$q_\sigma(x_\sigma | x_0) = \mathcal{N}(x_\sigma; x_0, \sigma^2 I).$$

Su score condicional sí es conocido:


$$\nabla_{x_\sigma} \log q_\sigma(x_\sigma | x_0) = -\frac{x_\sigma - x_0}{\sigma^2} = -\frac{\epsilon}{\sigma}.$$

Esto explica por qué la predicción de ruido aparece de manera natural. Si una red aprende $\epsilon_\theta(x_\sigma, \sigma) \approx \epsilon$, entonces puede inducir una estimación del score condicional mediante

$$s_\theta(x_\sigma, \sigma) \approx -\frac{\epsilon_\theta(x_\sigma, \sigma)}{\sigma}.$$

Score matching

El score $\nabla_x \log p(x)$ define un campo de direcciones hacia regiones de mayor densidad.



La figura resume la conexión. A la izquierda aparece un campo score asociado a una densidad. En el centro se muestra la perturbación gaussiana de una muestra limpia. A la derecha aparece la parametrización usada en difusión: una red predice ruido y esa predicción se reescala para obtener una aproximación del score.

5 La identidad marginal

La ecuación anterior se obtiene desde el score condicional. Para conectar con el score de la distribución perturbada marginal, definamos

$$p_\sigma(x) = \int q_\sigma(x | x_0) p_{\text{data}}(x_0) dx_0.$$

Esta es la densidad de datos después de añadir ruido gaussiano de escala σ . Su score cumple la identidad

$$\nabla_x \log p_\sigma(x) = \mathbb{E} [\nabla_x \log q_\sigma(x | x_0) | x].$$

Sustituyendo el score condicional gaussiano:

$$\nabla_x \log p_\sigma(x) = -\frac{1}{\sigma} \mathbb{E} [\epsilon | x_\sigma = x].$$

Por tanto,

$$\mathbb{E}[\epsilon | x_\sigma = x] = -\sigma \nabla_x \log p_\sigma(x).$$

Esta identidad es fundamental. La red entrenada con pérdida cuadrática no aprende el ruido exacto de cada muestra perturbada, porque ese ruido puede ser ambiguo dado x_σ . Aprende el promedio condicional del ruido. Ese promedio es proporcional al score marginal perturbado.


Observación 1 (Por qué la pérdida no baja a cero). Dado un punto perturbado x_σ , pueden existir varios pares (x_0, ϵ) compatibles. El objetivo MSE aproxima una esperanza condicional, no una inversión determinista perfecta de cada perturbación.

6 Objetivo de entrenamiento


La versión usada en el notebook entrena una red para predecir ruido:

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E}_{x_0, \sigma, \epsilon} \left[\|\epsilon - \epsilon_\theta(x_\sigma, \sigma)\|_2^2 \right].$$

El nivel de ruido σ se entrega como entrada a la red porque el campo score depende de la escala de perturbación. En el código se usa $\log \sigma$ como característica adicional, junto con las coordenadas de x_σ .



La figura muestra pares limpios y perturbados. Desde cada punto perturbado aparece una dirección asociada a $-\epsilon/\sigma$. No todas las flechas apuntan exactamente al centro de una componente: dependen del ruido particular usado para construir cada observación. Al promediar muchos ejemplos, emerge el score marginal.




La curva de pérdida baja inicialmente y luego se estabiliza. Esa estabilización es esperada por la ambigüedad descrita antes. El criterio relevante no es que la pérdida sea casi cero, sino que el campo aprendido se alinee con el score verdadero de la distribución perturbada.

7 Score aprendido

En el experimento sintético conocemos el score analítico, así que podemos comparar el campo verdadero con el aprendido. En un dataset real esta comparación directa no existe; precisamente por eso el ejemplo 2D es útil como banco de prueba conceptual.

Comparación de campos para $\sigma = 0.45$



La comparación muestra que la red captura la estructura principal del campo. Las flechas se orientan hacia regiones de mayor densidad y cambian de dirección en las zonas donde las componentes compiten. No debe esperarse una coincidencia perfecta: la red es pequeña, el entrenamiento es corto y el objetivo se estima por mini-lotes.

8 Denoising como movimiento por score


Si el score apunta hacia regiones de mayor densidad, entonces un paso pequeño en dirección del score puede reducir ruido. A partir de

$$s_\theta(x_\sigma, \sigma) \approx -\frac{\epsilon_\theta(x_\sigma, \sigma)}{\sigma},$$

un desplazamiento elemental puede escribirse como

$$x_{\text{new}} = x_\sigma + \sigma^2 s_\theta(x_\sigma, \sigma).$$

Esta expresión no es una cadena generativa completa. Es una lectura local: mover un punto perturbado en dirección del score tiende a acercarlo a regiones de mayor densidad.




La figura muestra puntos limpios, puntos perturbados y un paso guiado por el score aprendido. En varios casos el desplazamiento se orienta hacia la componente de densidad más cercana. Esto ilustra por qué denoising y score están conectados geoméricamente.

9 Dinámica de Langevin

Un campo score también puede usarse para generar muestras mediante una dinámica estocástica. Una forma simple es

$$x_{n+1} = x_n + \eta s_\theta(x_n, \sigma) + \sqrt{2\eta} z_n, \quad z_n \sim \mathcal{N}(0, I).$$

El término determinista mueve las partículas siguiendo el score; el término aleatorio mantiene exploración. En la práctica se usa una secuencia decreciente de niveles de ruido, lo que se conoce como una dinámica annealed.



La figura muestra partículas que inicialmente están dispersas y luego se concentran cerca de las regiones de alta densidad. Este procedimiento no reemplaza la formulación DDPM desarrollada antes; ofrece otra lectura de la generación: moverse con ayuda de un campo score aprendido.

10 Relación con DDPM

En DDPM discreto usamos tiempos t y coeficientes $\bar{\alpha}_t$:

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon.$$

Si reescribimos esta perturbación como una señal más ruido, el nivel efectivo de ruido depende de

$$\sigma_t^2 = \frac{1 - \bar{\alpha}_t}{\bar{\alpha}_t}$$

cuando se normaliza por la parte de señal. Bajo esa lectura, la red de DDPM que predice ϵ también contiene una estimación del score de una distribución perturbada. La forma exacta depende de la parametrización, pero la intuición central es la misma:

$$\epsilon_\theta \iff -\sigma s_\theta.$$

Esta equivalencia conceptual explica por qué los modelos de difusión pueden estudiarse desde la perspectiva de cadenas discretas o desde la perspectiva de campos score.

11 Limitaciones

El ejemplo 2D es deliberadamente simple. Permite calcular el score verdadero, visualizar campos vectoriales y observar partículas, pero no reproduce la complejidad de imágenes reales. En alta dimensión no podemos inspeccionar el campo completo; dependemos de pérdidas, muestras, métricas y evaluaciones cualitativas.

Además, el muestreo de Langevin usado aquí es solo una visualización conceptual. Los modelos modernos emplean discretizaciones, parametrizaciones y solvers más sofisticados. Aun así, el experimento captura el principio matemático que se necesitaba: denoising puede entenderse como aprendizaje de direcciones de alta densidad.

12 Resumen

Esta nota conectó la predicción de ruido con score matching. El score se define como

$$\nabla_x \log p(x).$$

Para perturbaciones gaussianas,

$$x_\sigma = x_0 + \sigma \epsilon,$$

el score condicional es

$$\nabla_{x_\sigma} \log q_\sigma(x_\sigma | x_0) = -\frac{\epsilon}{\sigma}.$$

Al entrenar una red para predecir ϵ , se obtiene una estimación del score perturbado:

$$s_\theta(x_\sigma, \sigma) \approx -\frac{\epsilon_\theta(x_\sigma, \sigma)}{\sigma}.$$

El experimento con mezcla gaussiana mostró la densidad, el score analítico, el score aprendido y una dinámica generativa guiada por ese campo. Con esto queda establecido el puente conceptual entre DDPM y modelos basados en score.

13 Preguntas de estudio

1. ¿Por qué el score no requiere conocer directamente la constante de normalización de una densidad?
2. ¿Qué representa la responsabilidad $r_k(x)$ en una mezcla gaussiana?
3. ¿Por qué el ruido suaviza el campo score?
4. ¿Cómo se obtiene $\nabla_{x_\sigma} \log q_\sigma(x_\sigma | x_0) = -\epsilon/\sigma$?
5. ¿Por qué la red aprende $\mathbb{E}[\epsilon | x_\sigma]$ y no necesariamente el ruido exacto?
6. ¿Cuál es la relación entre $\epsilon_\theta(x_\sigma, \sigma)$ y $s_\theta(x_\sigma, \sigma)$?
7. ¿Qué aporta la dinámica de Langevin como interpretación generativa?

14 Continuidad

El siguiente paso del curso es flow matching. Allí la generación se formulará como transporte entre distribuciones mediante campos de velocidad. La diferencia conceptual será importante: score matching aprende direcciones asociadas al gradiente de log-densidad, mientras que flow matching aprende un campo que mueve muestras desde una distribución inicial hacia la distribución de datos.