

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 10

Flow matching y transporte de probabilidad

Curso abierto OpenCourses.AI | 2026

Flow matching formula la generación como transporte: aprender un campo de velocidad que mueve una distribución simple hacia la distribución de datos.

1 Motivación

Los modelos DDPM construyen generación mediante una cadena inversa de denoising. Score matching ofrece una lectura geométrica de esa cadena: la red aprende direcciones relacionadas con gradientes de log-densidad. Flow matching introduce una tercera forma de organizar el mismo objetivo generativo: aprender una dinámica que transporte probabilidad.

La pregunta central cambia. Ya no se pregunta solamente qué ruido se debe retirar, sino qué velocidad debe tener una partícula ubicada en x en el tiempo t para que la población completa de partículas evolucione desde una distribución base p_0 hasta una distribución de datos p_1 .

Idea clave 1 (Transporte). Un modelo generativo puede verse como una transformación entre distribuciones. Flow matching parametriza esa transformación mediante un campo de velocidad dependiente del tiempo.

2 Campo de velocidad y ecuación de continuidad

Sea $p_t(x)$ una familia de densidades sobre $\mathbb{R}^d$, con $t \in [0, 1]$. Queremos que p_0 sea simple, por ejemplo una normal estándar, y que p_1 aproxime la distribución de datos.

Un campo de velocidad $v_t(x)$ transporta la familia p_t si las densidades satisfacen

$$\partial_t p_t(x) + \nabla_x \cdot (p_t(x) v_t(x)) = 0.$$

Esta es la ecuación de continuidad. Su interpretación es de conservación: la masa probabilística no se crea ni desaparece arbitrariamente; cambia de ubicación porque el campo v_t la desplaza.


Para una partícula individual, la evolución queda descrita por la ODE

$$\frac{dx(t)}{dt} = v_t(x(t)).$$

La generación consiste en muestrear $x(0) \sim p_0$ e integrar esta ODE hasta $t = 1$.

Flow matching

Aprender un campo de velocidad $v_\theta(x, t)$ que transporta una distribución simple hacia la distribución de datos.



La figura resume la formulación. A la izquierda aparece un camino de probabilidad, en el centro el campo de velocidades supervisadas y a la derecha la generación por integración de una ODE aprendida.

3 Camino lineal y supervisión

En el notebook usamos un camino condicional lineal. Se toman pares independientes

$$z \sim p_0, \quad x_1 \sim p_{\text{data}},$$

y se define


$$x_t = (1-t)z + tx_1.$$

La derivada respecto al tiempo es


$$\frac{dx_t}{dt} = x_1 - z.$$

Por tanto, para cada par (z, x_1) , conocemos una velocidad supervisada. El objetivo de entrenamiento es

$$\mathcal{L}(\theta) = \mathbb{E}_{z, x_1, t} \left[\|v_\theta(x_t, t) - (x_1 - z)\|_2^2 \right], \quad t \sim \mathcal{U}(0, 1).$$



La distribución base es una nube gaussiana centrada. La distribución de datos es una mezcla con tres modos. El problema generativo consiste en mover masa desde la primera geometría hacia la segunda.




El camino lineal muestra distribuciones intermedias. No debe interpretarse como una correspondencia semántica entre cada punto de ruido y cada dato; es una construcción de entrenamiento que provee posiciones intermedias y velocidades.

4 Velocidad promedio

Una dificultad importante es que por una misma región del espacio pueden pasar muchas trayectorias. Para un punto intermedio $x_t = x$, distintos pares (z, x_1) pueden inducir velocidades distintas. Con pérdida cuadrática, la solución óptima es un promedio condicional:

$$v^*(x, t) = \mathbb{E}[x_1 - z \mid x_t = x].$$

Esta ecuación aclara qué aprende la red. No memoriza pares; aproxima una propiedad agregada de la distribución de caminos.




La figura muestra velocidades de entrenamiento en diferentes tiempos. Al inicio, las trayectorias salen de una región concentrada. Cerca del final, las velocidades se organizan alrededor de los modos de la distribución objetivo.

5 Entrenamiento del campo

El modelo usado en el notebook es un MLP pequeño que recibe (x_t, t) y devuelve un vector en $\mathbb{R}^2$:

$$v_\theta : \mathbb{R}^2 \times [0, 1] \rightarrow \mathbb{R}^2.$$

La pérdida no mide directamente similitud entre muestras generadas y muestras reales. Mide error de regresión sobre velocidades. Por eso su valor absoluto no debe interpretarse como una métrica visual final.




La curva baja al comienzo y luego se estabiliza. Esto es esperable: el objetivo contiene ambigüedad condicional, porque varias velocidades son compatibles con posiciones intermedias cercanas.

6 Campo aprendido

Después del entrenamiento, el campo aprendido puede evaluarse en una grilla. Esta visualización es posible en dos dimensiones y permite ver la dependencia temporal del modelo:

$$(x, t) \mapsto v_{\theta}(x, t).$$



En tiempos tempranos, el campo debe actuar sobre muestras cercanas a la distribución base. En tiempos intermedios y finales, debe dirigir la masa hacia los modos. Esta dependencia temporal es esencial: un único campo estacionario no tendría la misma flexibilidad.

7 Generación por ODE


Con el campo entrenado, la generación se realiza resolviendo

$$\frac{dx(t)}{dt} = v_{\theta}(x(t), t), \quad x(0) \sim p_0.$$


El notebook usa Euler explícito:

$$x_{n+1} = x_n + \Delta t v_{\theta}(x_n, t_n).$$

Este integrador es simple y suficiente para fines pedagógicos. En aplicaciones reales se pueden usar integradores más precisos o estrategias de menos pasos.



La evolución muestra el transporte gradual de partículas. La nube inicial gaussiana se deforma y se separa hacia tres regiones.



La comparación final no es una evaluación estadística formal, pero valida cualitativamente la idea: el campo aprendido produce muestras con estructura similar a la distribución objetivo.

8 Relación con DDPM y score matching

DDPM, score matching y flow matching no son temas desconectados. Todos estudian formas de transformar una distribución simple en una distribución de datos.

En DDPM, el objeto operativo es una cadena de denoising. En score matching, el objeto geométrico es un campo score $\nabla_x \log p_t(x)$. En flow matching, el objeto central es un campo de velocidad $v_t(x)$ que satisface una ecuación de continuidad. La diferencia principal está en cómo se parametriza la dinámica y qué objetivo de entrenamiento se usa.

Observación 1 (Lectura del curso). Flow matching no invalida DDPM. Amplía el mapa conceptual: los modelos generativos modernos pueden describirse como cadenas estocásticas, campos score, ODEs de transporte o combinaciones de estas ideas.

9 Limitaciones

El camino lineal usado en el notebook no es el único posible. Tampoco resuelve un problema óptimo de transporte. Además, el experimento es bidimensional y usa un MLP muy pequeño. Estas restricciones son deliberadas: permiten ver el mecanismo sin ocultarlo detrás de arquitecturas grandes.

La lección no es que este MLP sea un modelo generativo competitivo. La lección es que aprender velocidades supervisadas puede producir una dinámica generativa completa.

10 Resumen

Flow matching formula la generación como transporte de probabilidad. Se define un camino p_t , se entrena un campo $v_\theta(x, t)$ para aproximar velocidades supervisadas y se generan muestras integrando una ODE desde p_0 hasta p_1 . Esta nota completa el puente entre la formulación discreta de DDPM y una visión continua basada en campos.

11 Preguntas de estudio

1. ¿Qué expresa la ecuación de continuidad en términos de conservación de masa probabilística?
2. ¿Por qué el campo aprendido en flow matching debe depender del tiempo?
3. ¿Qué diferencia hay entre una velocidad condicional $x_1 - z$ y el campo promedio $v^*(x, t)$?
4. ¿En qué sentido DDPM y flow matching son dos formas de transformar distribuciones?