

OpenCourses.AI

Modelos de difusión para IA generativa

Nota técnica 11

Espacios latentes y arquitecturas generativas modernas

Curso abierto OpenCourses.AI | 2026

Los modelos generativos modernos separan representación, dinámica generativa, condicionamiento y decodificación. La difusión latente opera sobre códigos, no directamente sobre píxeles.

1 Motivación

Los notebooks anteriores explicaron el núcleo matemático de la generación por difusión: ruido directo, denoising, muestreo inverso, condicionamiento, guidance, score matching y flow matching. Sin embargo, los sistemas modernos de imágenes no escalan solamente por cambiar la pérdida. Escalan porque reorganizan la arquitectura.

La idea central es trabajar en un espacio latente. En lugar de aplicar el modelo generativo sobre todos los píxeles, se comprime la imagen en una representación z , se modela la distribución de esos códigos y se decodifica el resultado. Esta separación reduce costo y permite incorporar condiciones complejas.

Idea clave 1 (Espacio latente). Un espacio latente no es simplemente una reducción de dimensión. Es una representación donde se espera conservar información relevante para reconstruir, editar o generar datos.

2 Autoencoder

Sea $x \in \mathbb{R}^d$ una imagen vectorizada. Un autoencoder define un codificador y un decodificador:

$$z = E_{\phi}(x), \quad \hat{x} = D_{\psi}(z).$$


El entrenamiento busca que la reconstrucción $\hat{x}$ preserve la información relevante de x :

$$\mathcal{L}_{AE}(\phi, \psi) = \mathbb{E}_{x \sim p_{\text{data}}} [\ell(x, D_{\psi}(E_{\phi}(x)))].$$

En autoencoders modernos, la pérdida puede combinar reconstrucción, regularización y términos perceptuales. En el notebook usamos PCA como versión lineal, transparente y barata de este principio.

Espacios latentes y arquitecturas generativas

Separar representación, dinámica generativa y decodificación permite escalar modelos de difusión.



La figura presenta la arquitectura completa: compresión perceptual, difusión en latentes y backbone generativo condicionado.


3 PCA como autoencoder lineal

PCA parte de datos centrados $x - \mu$ y calcula una base ortonormal de componentes principales. Si $W_m \in \mathbb{R}^{m \times d}$ contiene las primeras m componentes, entonces


$$z = (x - \mu)W_m^\top, \quad \hat{x} = zW_m + \mu.$$

Esta es una forma de autoencoder lineal. El codificador proyecta sobre un subespacio de dimensión m , y el decodificador reconstruye desde ese subespacio.

Muestras de QuickDraw por clase




El dataset usado contiene dibujos de cinco clases de QuickDraw. La variedad de formas permite observar cómo la compresión conserva rasgos globales, pero descarta detalles finos.



La varianza acumulada muestra que una parte importante de la variación de los datos puede representarse con menos de 784 coordenadas. Esto no garantiza calidad perceptual, pero sí evidencia redundancia estructural en el espacio de píxeles.

4 Compresión y reconstrucción

El compromiso fundamental de un espacio latente es costo contra fidelidad. Si m es pequeño, el código es barato, pero la reconstrucción pierde detalle. Si m crece, la reconstrucción mejora, pero el modelo generativo posterior opera sobre un espacio más grande.




La figura ilustra este compromiso. Con pocas componentes aparecen formas suaves y borrosas. Al aumentar la dimensión latente, los trazos se recuperan mejor. Esta limitación es esperable: PCA es lineal y no fue diseñado para preservar percepción humana.

Observación 1 (Reconstrucción). Una reconstrucción no es una copia exacta. Es el resultado de pasar por un cuello de botella representacional. Lo que se pierde en ese cuello de botella no puede recuperarse por el decodificador.

5 Geometría latente

Al proyectar sobre dos componentes principales, cada punto representa una imagen completa. El plano bidimensional no contiene toda la información, pero revela una organización global:

$$x \mapsto z = (z_1, z_2).$$



Las clases no se separan perfectamente porque PCA no usa etiquetas. Aun así, aparecen regiones con mayor concentración de ciertos tipos de dibujos. Esto anticipa una idea importante: los espacios latentes modernos buscan geometrías donde operaciones como interpolar, condicionar o editar sean más estables.

6 Interpolación

Si $z_a = E(x_a)$ y $z_b = E(x_b)$, una interpolación lineal se define como

$$z_\lambda = (1 - \lambda)z_a + \lambda z_b, \quad \lambda \in [0, 1].$$

Decodificar z_λ produce una secuencia de imágenes intermedias.



Con PCA, la interpolación es limitada y puede mezclar trazos de forma borrosa. En autoencoders neuronales, se espera que el espacio latente sea más adecuado para interpolaciones semánticas. La operación matemática, sin embargo, es la misma: moverse en el espacio de códigos y decodificar.

7 Difusión en latentes

En difusión latente, el proceso directo se aplica al código $z_0 = E(x_0)$, no a la imagen original:

$$z_t = \sqrt{\bar{\alpha}_t} z_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

El modelo aprende una predicción en el espacio latente:


$$\epsilon_\theta(z_t, t, c),$$

donde c es una condición. El objetivo de predicción de ruido conserva la forma conocida:

$$\mathcal{L}(\theta) = \mathbb{E} \left[\|\epsilon - \epsilon_\theta(z_t, t, c)\|_2^2 \right].$$

Después del muestreo, se obtiene una imagen decodificando:

$$\hat{x} = D_\psi(\hat{z}_0).$$



La figura decodifica latentes progresivamente perturbados. No es un proceso generativo completo; muestra únicamente qué significa añadir ruido en el espacio comprimido.

8 Backbones y condicionamiento

El autoencoder define el espacio donde se modela la distribución, pero la red generativa puede tener distintas arquitecturas. Dos familias importantes son U-Net y diffusion transformers.

Una U-Net conserva estructura espacial mediante convoluciones, reducciones de resolución y conexiones laterales. Esta estructura fue natural para imágenes porque combina información local

y global. Un diffusion transformer representa la imagen o el latente como una secuencia de tokens y usa atención para modelar relaciones globales.

La condición c puede ser una clase, texto, imagen, máscara o layout. En sistemas texto-imagen, el texto se codifica primero como embeddings, y luego esos embeddings condicionan la red mediante atención cruzada, concatenación o normalizaciones adaptativas.

Idea clave 2 (Arquitectura completa). El modelo moderno no es solo una red de denoising. Es un sistema compuesto por codificador, modelo generativo, mecanismo de condición y decodificador.

9 Relación con el curso

La difusión latente conserva el núcleo de DDPM: ruido directo, predicción de ruido y muestreo inverso. Lo que cambia es el espacio de trabajo. En vez de aprender sobre x_t , el modelo aprende sobre z_t . Esta decisión afecta costo, arquitectura y calidad final.

Score matching y flow matching siguen siendo relevantes. Ambos pueden formularse también en espacios latentes. Por tanto, el cierre del curso no reemplaza lo anterior; lo organiza dentro de una arquitectura moderna.

10 Limitaciones

PCA no es un autoencoder perceptual. Es lineal, no usa convoluciones, no aprende jerarquías visuales y no tiene una pérdida perceptual. Por eso las reconstrucciones pueden ser borrosas. Esta limitación no invalida el experimento; lo delimita.

El objetivo de la nota no es reproducir Stable Diffusion. Es entender por qué un modelo generativo puede operar sobre códigos y por qué esa decisión permite escalar modelos de imágenes.

11 Referencias

- Ronneberger, Fischer y Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*.
- Rombach, Blattmann, Lorenz, Esser y Ommer. *High-Resolution Image Synthesis with Latent Diffusion Models*.
- Peebles y Xie. *Scalable Diffusion Models with Transformers*.

12 Resumen

Los espacios latentes permiten separar representación, dinámica generativa y decodificación. En difusión latente, el proceso de ruido y denoising opera sobre z , no directamente sobre x . Esta decisión reduce costo y permite arquitecturas modernas con condicionamiento complejo. El curso queda cerrado con una lectura unificada: los modelos generativos aprenden transformaciones entre distribuciones, y la arquitectura define el espacio donde esas transformaciones se realizan.

13 Preguntas de estudio

1. ¿Qué información se pierde al pasar del espacio de píxeles al espacio latente?
2. ¿Por qué PCA es un autoencoder lineal, pero no un autoencoder perceptual moderno?
3. ¿Qué cambia al aplicar difusión sobre z_t en lugar de x_t ?